Desarrollo de una aplicación web para la identificación de síntomas específicos de distintos subtipos de cáncer de melanoma para una mejor profilaxis y un tratamiento más especializado

Memoria Trabajo Final de Máster

MU Bioinformática y Bioestadística

Área 3. Statistical Bioinformatics and Machine Learning

Autor: Manuel Rosario Marín Fernández

Tutora: Romina Astrid Rebrij

Profesor Responsable: Carles Ventura Royo

Fecha de entrega: 15/01/2023

Créditos/Copyright

© Manuel Rosario Marín Fernández

Esta obra está sujeta a una licencia de Reconocimiento - NoComercial - SinObraDerivada 3.0 España de Creative Commons (CC BY-NC-ND 3.0 ES)

Dedicatoria:

Gracias a mis padres, por apoyarme y creer en mí incluso yo no pude.

Gracias a Erika, por ser un pilar de estabilidad y apoyo durante todo este proyecto

FICHA DEL TRABAJO FINAL

Título del trabajo:	*"Desarrollo de una aplicación web para la identificación de síntomas específicos de distintos subtipos de cáncer de melanoma para una mejor profilaxis y un tratamiento más especializado"*
Nombre del autor:	*Manuel Rosario Marín Fernández*
Nombre del consultor/a:	*Romina Astrid Rebrij*
Nombre del PRA:	*Carles Ventura Royo*
Fecha de entrega (mm/aaaa):	*01/2023*
Titulación o programa:	*Máster universitario en Bioinformática y bioestadística*
Área del Trabajo Final:	*Área 3. Statistical Bioinformatics and Machine Learning*
Idioma del trabajo:	*Castellano*
Palabras clave	*Aprendizaje automático, ciencias ómicas, aplicaciones web*

Resumen del Trabajo(máximo 250 palabras):

Las ciencias ómicas están al alza en panorama actual dentro del marco de la salud debido a la ingente cantidad de datos que se han generado a lo largo de estos últimos años. La Bioinformática permite un análisis de estas cantidades masivas a un nivel previamente inalcanzable. Gracias a esta herramienta en constante desarrollo, se pueden obtener nuevos datos y conexiones relevantes que abren un gran abanico de oportunidades, notablemente para la creación y el perfilado de tratamientos más especializados, potencialmente mejorando la profilaxis .

Este Trabajo de Fin de Máster, se ha centrado en las Reglas de Asociación como técnica de aprendizaje automático(ML) principal para la extracción de dependencias y conocimiento útil. Los resultados muestran que este tipo de técnicas proporcionan grandes ventajas para poder analizar y comprender grandes muestras de datos

biológicos. Para aumentar el potencial explicativo de las reglas extraídas, se propone desarrollar una aplicación web interactiva en base a las mismas.

Abstract(in English, 250 words or less):

The “omics” sciences are on the rise in the current healthcare landscape due to the enormous amount of data that has been generated over the last few years. Bioinformatics allows an analysis of these massive amounts at a previously unattainable level. Thanks to this constantly developing tool, new data and relevant connections can be obtained opening up a wide range of opportunities, notably for the creation and profiling of more specialized treatments, potentially improving prophylaxis.

This Master Thesis has focused on Association Rules as the main machine learning technique for the extraction of dependencies and useful knowledge. The results show that this type of techniques provide great advantages to be able to analyze and understand large samples of biological data. To increase the explanatory potential of the extracted rules, it is proposed to develop an interactive web application based on them.

RESUMEN:

Las ciencias ómicas están al alza en panorama actual dentro del marco de la salud debido a la ingente cantidad de datos que se han generado a lo largo de estos últimos años. La Bioinformática permite un análisis de estas cantidades masivas a un nivel previamente inalcanzable. Gracias a esta herramienta en constante desarrollo, se pueden obtener datos y nuevas conexiones relevantes que abren un gran abanico de oportunidades, notablemente para la creación y el perfilado de tratamientos más especializados, potencialmente mejorando la profilaxis .

Este Trabajo de Fin de Máster, se ha centrado en las Reglas de Asociación como técnica de Aprendizaje Automático(ML por sus siglas en inglés) principal para la extracción de dependencias y conocimiento útil. Los resultados muestran que este tipo de técnicas proporcionan grandes ventajas para poder analizar y comprender grandes muestras de datos biológicos. Para aumentar el potencial explicativo de las reglas extraídas, se propone desarrollar una aplicación web interactiva en base a las mismas.

Palabras clave: Aprendizaje automático, bioinformática, cáncer de melanoma, ciencias ómicas, inteligencia artificial, reglas de asociación, aplicaciones web.

ÍNDICE

1. INTRODUCCIÓN:.....9
1.1 Contexto y justificación del Trabajo:.....9
1.2 Objetivos:.....10
1.2.1 Objetivo general:.....10
1.2.2 Objetivos específicos:.....10
1.3 Impacto de sostenibilidad, ético social y de diversidad:.....10
1.4 Enfoque y Metodología:.....11
1.5 Planificación:.....12
1.6 Productos obtenidos:.....14
1.7 Sumario de los siguientes apartados:.....15

2. ESTADO DEL ARTE:.....15
2.1 Cáncer de melanoma:.....15
2.2 Bioinformática interdisciplinar:.....16

3.MATERIALES Y MÉTODOS:.....17
3.1 Estudio base:.....17
3.1.1 TCGA-SKCM:.....17
3.1.2 Pipeline/Flujo de trabajo:.....17
3.1.3 Variables de interés:.....18
3.2 Entorno y paquetes utilizados:.....20
3.2.1 Entornos de trabajo:.....20
3.2.2 Paquetes R.....22
3.2.3 Paquetes en Python.....23
3.3 Técnicas de ML utilizadas:.....24
3.3.1 Reglas de asociación (RAs).....24
3.3.2 Algoritmo FP Growth:.....27

4. ANÁLISIS DE LOS DATOS:.....28
4.1 Exploración y formato:.....28
4.2 Análisis de RAs extraídas:.....32

5. DESARROLLO DE LA APP SHINY:.....36
5.1 Diseño de la UI:.....36
5.2 Escritura del código fuente y despliegue de la app:.....40
5.3 Vista general de la app:.....42
5.3.1 Título de la app y menú desplegable:.....42
5.3.2 Secciones de la app:.....43

6. IMPLEMENTACIÓN Y USO:.....47

7. CONCLUSIONES Y TRABAJOS FUTUROS:.....48

8. GLOSARIO:.....50

9. BIBLIOGRAFÍA:.....51

1. INTRODUCCIÓN:

1.1 Contexto y justificación del Trabajo:

La ingente cantidad de datos dentro de las ciencias ómicas han propiciado una revolución técnica que ha permitido analizar grandes cantidades de datos. Y debido al enorme volumen y complejidad de los mismos, es obvio que estos para dichos análisis tienen que ser utilizados ordenadores y, además, requieren técnicas de análisis de la Inteligencia Artificial (IA) y ML basadas en aprendizaje supervisado, no supervisado o por refuerzo, entre otras. En el campo de la oncología se ha asentado el uso de este tipo de técnicas para mejorar el diagnóstico [17].

En concreto, el Aprendizaje No supervisado permite descubrir patrones o asociaciones en los datos sin especificar previamente una variable de salida. No hay una variable que establezca el valor a predecir. Se trata, simplemente, de dejar que hablen los datos para descubrir nuevas relaciones entre variables o nuevos grupos en los que se organizan los datos, lo que permite detectar patrones de síntomas desconocidos anteriormente [19]

El Atlas del Genoma del Cáncer (TCGA)[20], es un programa histórico de genómica del cáncer, caracterizó molecularmente más de 20.000 muestras primarias de cáncer y muestras normales emparejadas que abarcan 33 tipos de cáncer. Entre los proyectos que han desarrollado se encuentra TCGA-SKCM (TCGA-Skin Cell Melanoma)[6], en el cual se describe el panorama de las alteraciones genómicas en los melanomas cutáneos.

Según el tipo de análisis que se realice sobre la información obtenida de las muestras, el patrón que se identifique puede utilizarse para la predicción de un pronóstico de forma más certera o precoz, la clasificación automática de la tipología del tumor o la identificación de distintos subtipos del tumor para elaborar tratamientos más específicos, entre otras aplicaciones.

Siguiendo este potencial identificador se pueden generar unos “perfiles de paciente”, que servirían como base para una medicina más especializada. Para acercar este tipo de herramientas bioinformáticas a unos usuarios que carecen de conocimientos de informática avanzada, se pueden implementar diversas interfaces de usuario (UIs) que facilitan el entendimiento de los datos y muestran solo la información pertinente.

1.2 Objetivos:

1.2.1 Objetivo general:

Desarrollar una aplicación web que permita visualizar las relaciones entre variables de datos sobre el cáncer de melanoma, para una mejor clasificación y posible establecimiento de perfiles clínicos.

1.2.2 Objetivos específicos:

1. Enriquecer el conocimiento propio sobre las técnicas de ML, de análisis visual y sobre el cáncer de melanoma.
2. Extraer y analizar los patrones e interacciones que tienen mayor relevancia dentro del conjunto de datos seleccionado .
3. Crear un catálogo de mutaciones asociadas a los patrones con impacto clínico para el pronóstico de la enfermedad
4. Desarrollar una aplicación web interactiva para analizar los resultados con ayuda de herramientas de análisis visual.

1.3 Impacto de sostenibilidad, ético social y de diversidad:

Este Trabajo Final (TF) podría tener cierto impacto positivo en los recursos utilizados para tratamientos médicos, ya que al generar un “perfil de paciente” se acota y personaliza el tratamiento. De este modo, se evitaría gastar recursos en un tratamiento erróneo o menos efectivo que podrían destinarse a otra persona. El impacto sería mayor cuanta más gente tuviera su propio perfil de paciente. La posibilidad de promover la medicina personalizada es una de las motivaciones de este TF.

Las posibles implicaciones éticas y de responsabilidad social vienen del uso fraudulento de este tipo de aplicación para utilizar los datos sanitarios personales de manera maliciosa, por ejemplo, si una persona hiciera uso de esta aplicación para conocer los factores de riesgo que presenta otra persona y los indujera en alguien con riesgo. Otra cuestión sería la privacidad, ya que para hacer el perfilado de una persona se necesitan datos muy sensibles de su salud como su historial médico o su genoma. Por otro lado, este perfilado de pacientes podría dar lugar a un sesgo de personas, por ejemplo, en la contratación de personas con poco riesgo de cáncer de melanoma. Este TF se ha hecho de manera controlada, con datos de libre acceso, asegurando que no se vulnera la privacidad de ninguna persona. Por último, durante la duración del proyecto no se ha identificado ningún sesgo en aspectos de diversidad o derechos humanos. Si bien este podría venir directamente de los datos, este se podría corregir utilizando un conjunto de datos más grande y homogéneo, utilizando cohortes con diversidad racial y de género, procedentes de un mayor número de grupos sociales. En gran medida, este TF quiere permitir el acceso a personas a un desglose de ciertas características, específicamente sobre el cáncer de melanoma, sin necesidad de conocimientos informáticos previos, por lo que la accesibilidad se ha tenido en cuenta.

1.4 Enfoque y Metodología:

Partiendo de la idea inicial del TF, se han estudiado los recursos necesarios para poder llevarla a cabo. Se ha empezado con una recopilación de los datos y las técnicas de ML empleados. De la misma manera, se ha recogido el conjunto de librerías y entornos que se han utilizado.

A la hora de abordar el análisis de datos se han tomado los datos pretratados a través de las bibliotecas del *TCGAbiolinks*[21] , seguido del diseño y análisis de los mismos con ayuda de técnicas de aprendizaje no supervisado. Para ello, se han utilizado algoritmos de ML como FP-growth para generar estructuras con los itemsets más frecuentes. Posteriormente, se ha procedido a la extracción y selección de las Reglas de Asociación (RAs) teniendo en cuenta estos itemsets.

En cuanto a la creación de la aplicación web, se ha optado por el paquete Shiny dada su accesibilidad de uso y su capacidad de crear páginas interactivas para explorar la información.

1.5 Planificación:

El TF se ha estructurado siguiendo una planificación con hitos en tareas más específicas y de menor complejidad que se pueden abordar con mayor facilidad. En la siguiente tabla aparecen las tareas que se llevaron a cabo:

Tabla 1: Planificación del TFM

ID	Descripción	Fecha de inicio	Fecha de fin
1	**PEC1**	**23/sep/2022**	**17/oct/2022**
1.1	Recopilación y análisis exploratorio de los datos.	23/sep/2022	26/sep/2022
1.2	Definición de los algoritmos que serán aplicados.	26/sep/2022	29/sep/2022
1.3	Desarrollo del plan de trabajo.	29/sep/2022	04/oct/2022

1.4	Entrega y retroalimentación del plan de trabajo.	04/oct/2022	17/oct/2022
2	**PEC2**	**18/oct/2022**	**21/nov/2022**
2.1	Exploración de las técnicas y herramientas necesarias.	18/oct/2022	22/oct/2022
2.2	Entender el formato de entrada de los datos que requieren los algoritmos seleccionados	23/oct/2022	25/oct/2022
2.3	Preprocesamiento de datos.	25/oct/2022	03/nov/2022
2.4	Diseño y realización del análisis experimental mediante RAs y técnicas de visualización.	04/nov/2022	10/nov/2022
2.5	Validar los resultados obtenidos (RAs).	04/nov/2022	10/nov/2022
2.6	Documentación de todo el trabajo realizado para la memoria.	11/nov/2022	14/nov/2022
2.7	Optimizar esquema y presentación	15/nov/2022	18/nov/2022
2.8	Entrega y retroalimentación	19/nov/2022	21/nov/2022
3	**PEC3**	**22/nov/2022**	**24/dic/2022**
3.1	Análisis de resultados.	22/nov/2022	26/nov/2022
3.2	Selección de las mejores RAs	22/nov/2022	26/nov/2022
3.3	Aprendizaje de desarrollo de aplicaciones empleando Shiny.	27/nov/2022	01/dic/2022
3.4	Definición del esquema de la aplicación.	02/dic/2022	12/dic/2022
3.5	Desarrollo de la aplicación web con Shiny.	02/dic/2022	12/dic/2022
3.6	Subir la aplicación al servidor de Shiny.	12/dic/2022	14/dic/2022
3.7	Probar el funcionamiento de la aplicación.	12/dic/2022	14/dic/2022
3.8	Documentación de todo el trabajo realizado para la memoria.	15/dic/2022	19/dic/2022
3.9	Entrega y retroalimentación	20/dic/2022	24/dic/2022
4	**PEC4**	**27/dic/2022**	**15/ene/2023**
4.1	Optimizar esquema y presentación de la memoria.	27/dic/2022	15/ene/2023
4.2	Optimizar esquema y presentación del código fuente.	27/dic/2022	15/ene/2023
4.3	Elaboración de la presentación	09/dic/2022	15/ene/2023
5	**DEFENSA PÚBLICA**	**23/ene/2023**	**03/feb/2023**

Utilizando como base la planificación de la tabla anterior, el TF se desglosó en 5 fases principales:

- Definición del plan de trabajo: Planteamiento y contextualización del proyecto a grandes rasgos, búsqueda de la librerías y bibliografía necesarias.
- Desarrollo del TF 1: Exploración de las herramientas y técnicas necesarias para el análisis planteado, diseño experimental y procesamiento de los datos, validación de los resultados.
- Desarrollo del TF 2: Análisis y selección de resultados, aprendizaje sobre desarrollo de aplicaciones(apps) con *Shiny* y el propio desarrollo de la app.
- Perfilado y cierre de memoria: Optimización de la memoria, el notebook utilizado y la app. Elaboración de la presentación
- Defensa: Exposición pública ante el Tribunal de Evaluación

En el siguiente diagrama de Gantt se puede visualizar el flujo de las actividades mencionadas de forma global.

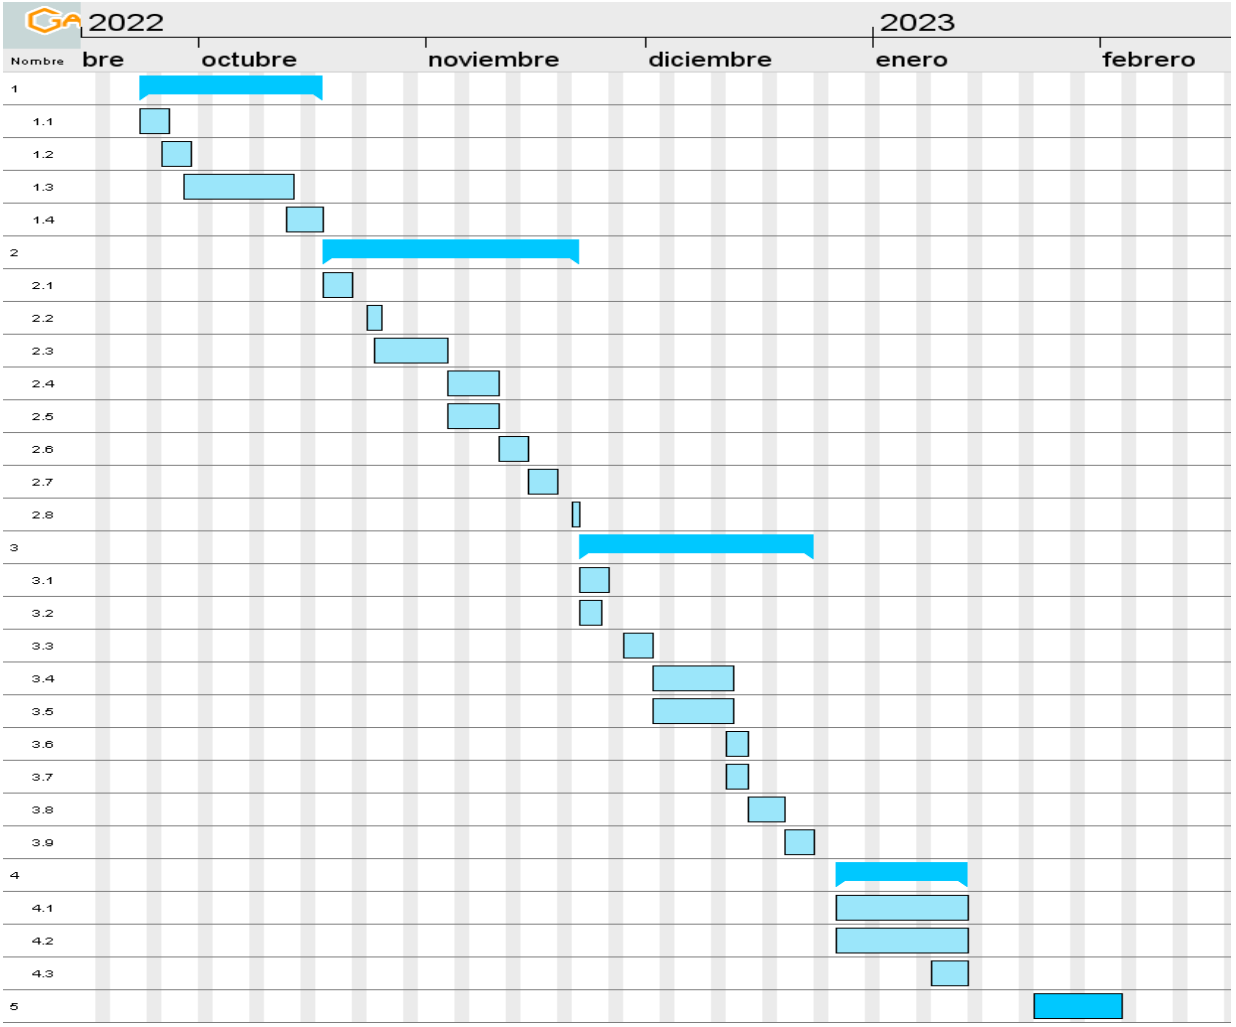

Fig. 1: Diagrama de Gantt sobre el TFM (GanttProject App).

1.6 Productos obtenidos:

Al concluir el desarrollo de este TF, se han obtenido como producto un notebook donde se encuentra el pipeline con el tratamiento de datos efectuado en formato"*.ipynb*" , un conjunto de RAs de interés en formato "*.csv*" y una app Shiny donde se pueden explorar este

1.7 Sumario de los siguientes apartados:

Tras introducir el proyecto, los siguientes apartados abordan en detalle la elaboración del trabajo. De esta manera, se comienza explicando el estado del arte perteneciente al desarrollo de app y a la medicina personalizada, así como el estudio base del cual se extraen los datos tratados en este TF y las herramientas y técnicas de ML utilizadas para su procesamiento y posterior transformación en app.

Seguidamente se explica el proceso de análisis y tratamiento de datos, los gráficos obtenidos como resultado y finalmente la creación y funcionamiento de la app de visualización cerrando el documento con las conclusiones. El contenido está dividido en apartados compuestos por varias secciones y se complementa con archivos y figuras.

2. ESTADO DEL ARTE:

Este proyecto se enmarca dentro del ámbito biosanitario, en concreto en el acercamiento del personal biosanitario a las potentes herramientas que la bioinformática, en concreto el ML y la IA ofrecen actualmente. La selección de una base de datos potente y abierta, así como una temática interesante dio como resultado la elección de cáncer de melanoma como base del TF.

2.1 Cáncer de melanoma:

La incidencia global de este tipo de cáncer ha estado incrementando rápidamente a lo largo de las últimas 5 décadas, posicionándose como uno de los tipos de cáncer más comunes [23]. Su incidencia varía según la edad, abundando más en personas mayores, pero también con el sexo y la etnicidad siendo más prominente en personas con piel más clara. Las tasas de este tipo de cáncer se ven influenciadas también por la latitud poblacional ya que la incidencia solar, principal causante de este tipo de cáncer, varía en función de la misma.[23]

Actualmente existen multitud de acercamientos a esta problemática, la gran mayoría se sirve de la tecnología en mayor o menor medida. Ciertas técnicas como la tomografía computerizada se han utilizado para detectar metástasis [29]. Sin embargo , las soluciones preventivas parecen pasar sobre todo por la ómicas, siendo la genómica una de las más populares[30][31]

2.2 Bioinformática interdisciplinar:

Las técnicas de ML en la actualidad son ampliamente utilizadas en el campo de la salud, con el objetivo de procesar datos y obtener información relevante a partir de los mismos[17]. Sin embargo, estas técnicas requieren un conocimiento previo para su correcta utilización por lo que tienen poca accesibilidad. Un método emergente para paliar esta divergencia viene desde el campo de la Bioinformática Traslacional (TBI por sus siglas en inglés)[24] (ver figura 2).

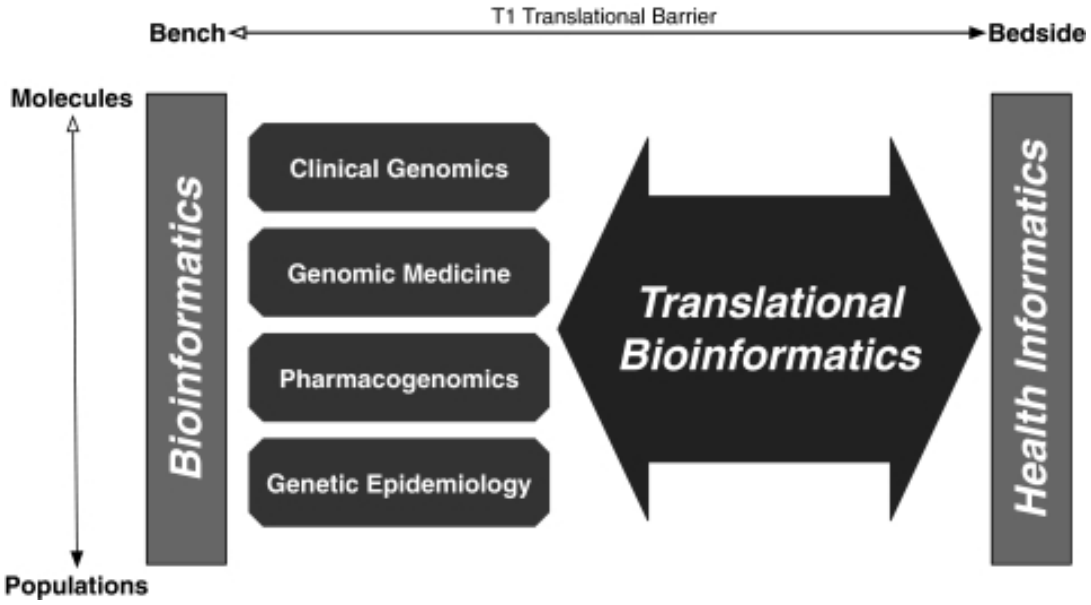

Fig. 2: Figura explicativa de la Bioinformática Traslacional como puente entre disciplinas

Existen antecedentes de herramientas visuales siendo utilizadas para la detección de patrones complejos dentro de los datos[25][26] y aplicaciones basadas en este concepto[27]. El crecimiento de este campo implica el desarrollo y uso de métodos computacionales que puedan razonar sobre las enormes cantidades de datos de ciencias de la vida que se recogen y almacenan con el fin de crear nuevas herramientas para la medicina[28]. Este TF pretende acortar las distancias entre las cantidades masivas de datos "crudos" y los profesionales no versados en bioinformática, tomando inspiración de este campo.

3.MATERIALES Y MÉTODOS:

3.1 Estudio base:

3.1.1 TCGA-SKCM:

Para el desarrollo del presente TF, se ha utilizado una base de datos procedente del proyecto TCGA-SKCM[6], un estudio perteneciente a TCGA[20], un programa genómica del cáncer de gran relevancia que caracterizó molecularmente más de 20.000 muestras primarias de cáncer y muestras normales emparejadas que abarcan 33 tipos de cáncer, entre ellos el cáncer de melanoma.

Los autores de [6] realizaron un estudio sobre los datos de expresión génica de melanoma procedentes de [20] obtenidos con secuenciación de ARN, en el cual se describe el panorama de las alteraciones genómicas en los melanomas cutáneos mediante el análisis multifactorial (de ARN, ADN y proteínas) de tumores de melanoma primarios y/o metastásicos de 331 pacientes. Durante este proyecto se caracterizaron muestras con información genómica, transcriptómica, epigenética y características clínico-patológicas (estadío tumoral, metástasis, tratamiento, etc.). En él identificaron 4 subtipos de mutaciones dependiendo del patrón de genes significativamente mutados (NF1 mutante, BRAF mutante, RAS mutante y Triple-WT)[6] sobre los cuales se ha centrado el TF para realizar el análisis de RAs.

3.1.2 Pipeline/Flujo de trabajo:

A continuación se explica el pipeline que los investigadores de [6] propusieron para tratar los datos en la etapa de preprocesamiento.

En primer lugar se descargó un set de datos completo desde TCGA[20] a través de las librerías de *TCGAbiolinks*[21]. Para facilitar el flujo de trabajo se descargaron los datos de expresión génica ya procesados aplicando el paquete *rsem*[5]. Este paquete permite transformar los datos normalizando el número de copias de ARNs, alteración necesaria para adaptar y facilitar el análisis de estos datos.

Una vez descargados los datos se aplicó una transformación de logaritmo en base 2 mediante la función *log2*, preferida por la conveniencia de las propiedades de su distribución a la hora de ser representadas. Seguidamente, se hizo un centrado de mediana mediante la función *median* con la cual se completó la normalización de los datos. De este modo se corrigen en parte los posibles errores y variabilidad que hubieran tenido los datos, minimizando el error

humano e instrumental.

A continuación se ejecutó una eliminación de “genes planos” sobre los datos, seleccionando solo los genes con la mayor varianza, lo que permitió centrar los recursos y tiempo en genes que presentaban mayor potencial discriminatorio para con las muestras, lo que fue de gran importancia para crear aglomeraciones(clusters) dentro de los datos. Posteriormente esta información fue preprocesada y enriquecida con variables clínicas, siendo seis de ellas destacadas por los autores de [6] en su estudio.

3.1.3 Variables de interés:

Tomando como referencia las variables destacadas en [6] el TF se centra en ellas por la información que contienen:

- **MUTATIONSUBTYPES:** indica cuál de los tipos de mutaciones más frecuentes se ha encontrado en cada instancia. Puede tomar los siguientes valores:
    - ***NF1_Any_Mutants:*** representa el tercer grupo más frecuente de mutaciones referentes al gen NF1, con una presencia del 14%.
    - ***BRAF_hotspot:*** comprende el grupo de mutaciones más frecuente con una presencia en las instancias del 52%.
    - ***RAF_hotspot:*** conforma el segundo grupo más frecuente de mutaciones.
    - ***Triple_WT:*** engloba un grupo heterogéneo de mutaciones que no forman parte de los otros subtipos.

- **MIRCluster:** fruto del clustering de secuenciación de microRNA mediante el programa iCluster [6]. Puede tomar los siguientes valores:

- MIR.type.1
- MIR.type.2
- MIR.type.3
- MIR.type.4.

- **UV_signature:** indica si la instancia presenta rasgos provocados por radiación UV. Puede tomar dos posibles valores:
  - ***UV signature:*** engloba las instancias que presentan las transiciones T>C más del 60% o las mutaciones CC>TT representan más del 5%.
  - ***Not UV:*** representa a las instancias que no cumplen ninguna de las dos condiciones anteriores.

- **LYMPHOCYTE.SCORE (LScore):** medida de la distribución y densidad de los linfocitos infiltrantes de tumores (TIL) utilizando el sistema de scoring de TCGA/Park [13]. Posee un rango de valores entre 0 y 6.
- **RNASEQ-CLUSTER_CONSENHIER:** generado tras el análisis mediante clustering jerárquico consensual dentro de [6]. Posee tres clases:
  - ***MITF-low:*** caracterizado por baja expresión de los genes relacionados con la pigmentación y la expresión epitelial.
  - ***keratin:*** distinguible por la alta expresión de genes asociados a la producción de queratina, epitelio y también del desarrollo neuronal.
  - ***immune:*** destacado por la sobreexpresión de genes relacionados con el sistema inmune y sus células y moléculas asociadas.
- **MethTypes201408**: extraída del clustering de tipos de metilación sobre diferentes locus CpG [13]. Los valores que puede tomar son:
  - ***CpG island-methylated:*** expresado por instancias con metilación en las islas CpG

- ***Hyper-methylated:*** tomado por instancias con alta metilación
- ***Normal-like:*** exhibido por instancias con metilación normal
- ***Hypo-methylated:*** lo presentan las instancias con baja metilación

3.2 Entorno y paquetes utilizados:

3.2.1 Entornos de trabajo:

Inicialmente el TF se desarrolló en *Jupyter Notebook*, un entorno interactivo computacional basado en la web, que permite la edición y ejecución de documentos y su lectura mientras se describe el análisis de datos. Al mostrar incompatibilidad con una de las librerías de visualización el TF migró a *Google Colaboratory (Google Colab)* puesto que este entorno sí era compatible y estaba basado en Jupyter. Como característica adicional Google Colab proporciona a sus usuarios acceso gratuito a recursos informáticos de alto rendimiento, como GPU y TPU, esenciales para entrenar modelos de forma rápida y eficaz[32]. Este entorno se utilizó principalmente para el análisis de datos y la extracción de RAs (ver figura 3)

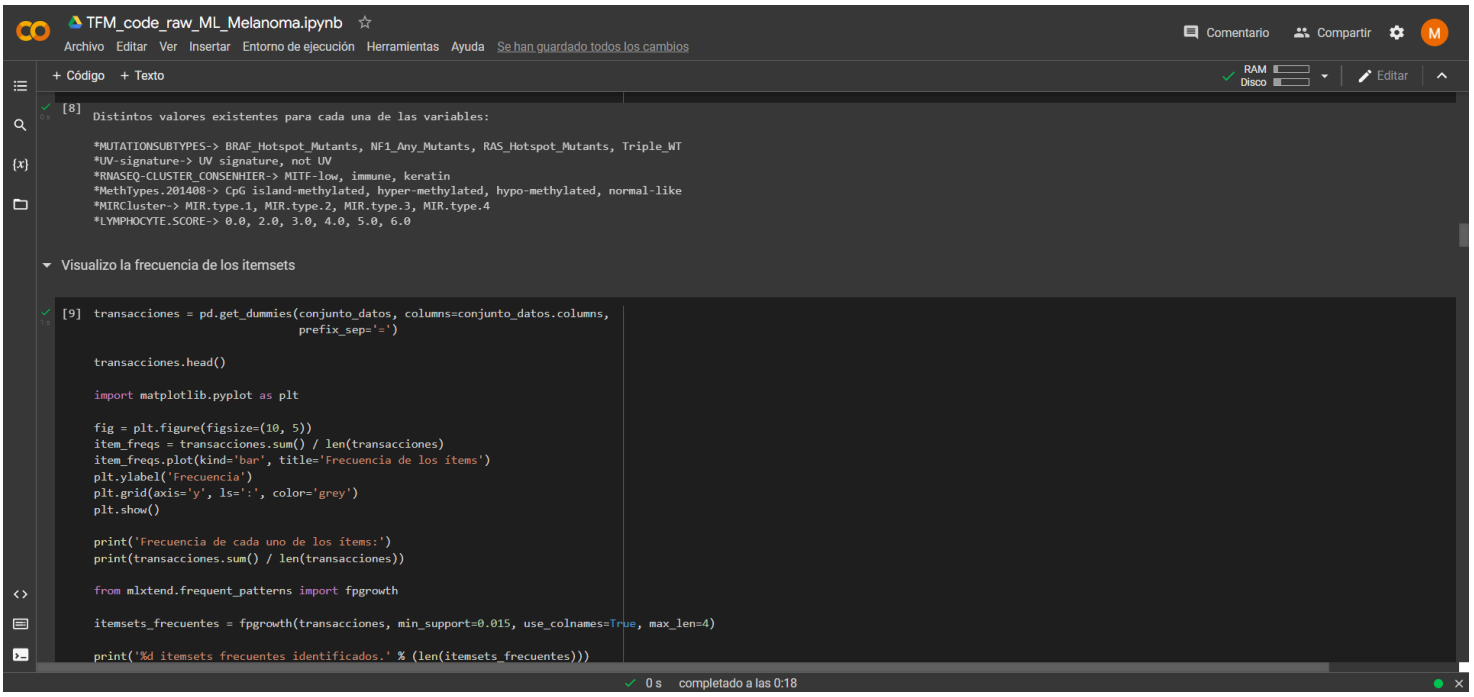

Fig. 3: Captura de pantalla mostrando el entorno Google Colab

Por último para producir la app web, se utilizó *RStudio* como entorno de trabajo final para el desarrollo de la app en sus etapas de inicialización y personalización (ver figura 4).

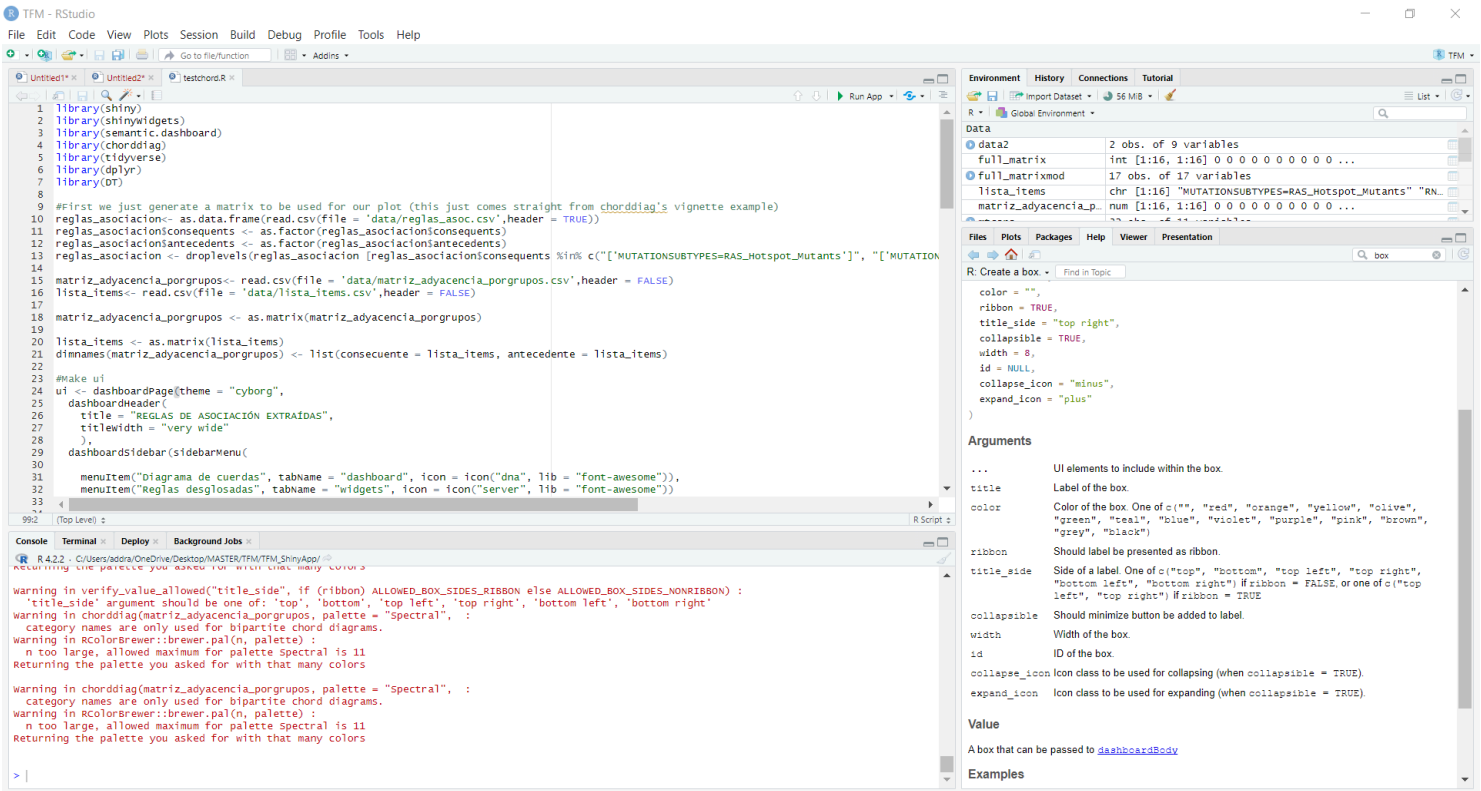

Fig. 4: Captura de pantalla mostrando el entorno RStudio

3.2.2 Paquetes R

A lo largo del proyecto se han utilizado varias librerías de recursos de *R* ya que este lenguaje se centra más en el tratamiento de datos y el análisis estadístico, destacando las siguientes:

- **Chorddiag**

Este paquete permite crear diagramas de acordes interactivos utilizando la biblioteca de visualización de JavaScript D3 desde dentro de R utilizando el marco de interconexión htmlwidgets. Los diagramas de cuerdas muestran relaciones dirigidas entre un grupo de entidades.[14]

- **rpy2**

Es una interfaz para R que se ejecuta embebida en un proceso Python, en el caso de este TF dentro del notebook de este proyecto.[9]

- **Shiny**

Utilizado para la realización de la aplicación (app) que permite la visualización de los datos procesados así como las conclusiones extraídas.[18]

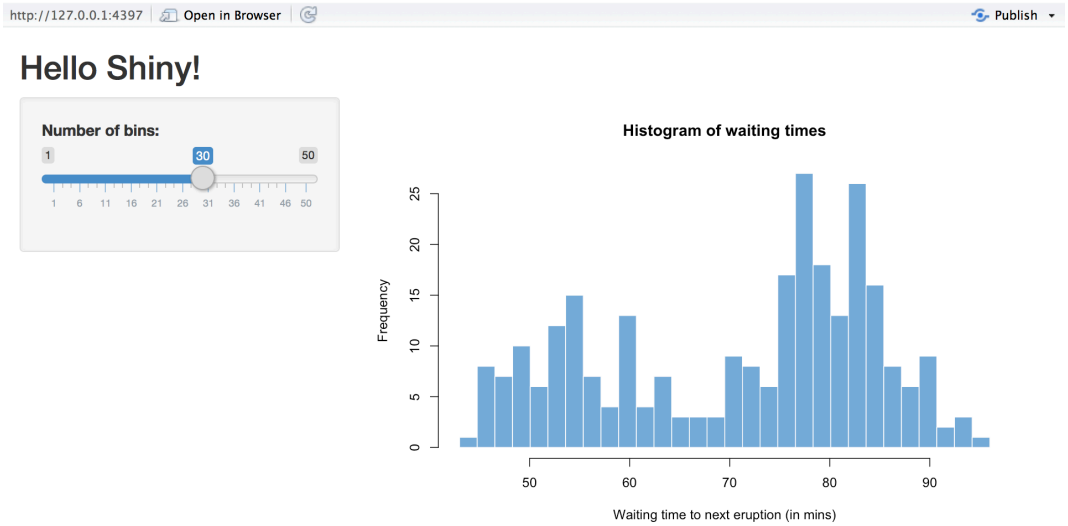

Fig. 5: Captura del ejemplo “Hello World” de la web Shiny[18]

3.2.3 Paquetes en Python

Este lenguaje ha sido utilizado principalmente para el procesamiento de datos, su análisis exploratorio, visualizaciones e inferencia y validación de modelos. Se destacan los siguientes recursos:

- **MLXTEND**

Biblioteca de herramientas de ML y ciencia de datos para Python. Dentro de ella encontramos el algoritmo *FP-Growth*[22], un algoritmo clásico de extracción de reglas de asociación basado en la identificación de itemsets frecuentes y la función *association_rules()*[33].

- **Matplotlib**

Paquete de generación de gráficos 2D a partir de listas o arrays de datos, dirigido principalmente a la visualización de datos científicos, de ingeniería y financieros.[8]

Adicionalmente se han utilizado librerías más comunes de Python como pandas[4], plotly[15] y NumPy[10] para permitir la lectura de archivos *".csv"*, creación y edición de gráficos simples y matrices y vectores, así como numerosas operaciones matemáticas.

3.3 Técnicas de ML utilizadas:

3.3.1 Reglas de asociación (RAs)

Al no conocer las interacciones que pueda haber entre las variables de los datos, se ha optado por el aprendizaje no supervisado como método para descubrir nuevos patrones o asociaciones. Existen varios algoritmos de aprendizaje no supervisado:

Model	Learning task
Unsupervised learning algorithms	
Association rules	Pattern detection
k-means clustering	Clustering

Fig. 6: Algoritmos de aprendizaje no supervisado [16].

Así pues en este TFM se aplicarán ambas técnicas, con especial hincapié en las RAs. Estas se utilizan para representar dependencias entre los elementos de un modelo lógico A → C, siendo A el antecedente y C el consecuente de la regla, y A y C son conjuntos de elementos de la Base de Datos (BD) cuya intersección es vacía. Entonces, A → C indica que cuando en un ejemplo de la BD aparecen los elementos de A, con una alta probabilidad también aparecen los elementos de C.

La utilización de este tipo de reglas se aplicó inicialmente al análisis de base de datos con información sobre los productos comprados por clientes de un supermercado [2] y actualmente se ha extendido a una gran cantidad de problemas [12]. Por ejemplo, la regla *Consola*→ *Videojuego* podría ser extraída del repositorio de ventas de una superficie comercial, indicando que un cliente que compre una consola también comprará un videojuego. La nomenclatura de los términos empleados en las RAs y su extracción, se ha visto muy influenciada por sus orígenes, teniendo como ejemplo que a los conjuntos de elementos se les llaman *itemsets*, y a los ejemplos de la BDs se les llama *transacciones*.

Antes de extraer estas reglas, se preprocesa el conjunto de datos (eliminando variables confusas, etc) y se decide qué se considera como ítems y transacciones. Distinguimos los siguientes tipos de ítems:

- Ítems como elementos que aparecen en una instancia. Esta instancia es una lista de elementos (por ejemplo, una lista de productos de una tienda)
- Ítems como pares variable/valor, existiendo un número fijo de variables y un valor de cada variable por instancia dentro del conjunto de datos.

En el caso de este TF el número de variables que forma el conjunto de datos es fijo y cada instancia tiene un valor para cada variable, por lo que un ítem es un par variable/valor y cada instancia es una transacción con una lista de ítems. A su vez, hemos tratado los diferentes valores de cada variable como una categoría.

Las RAs son normalmente evaluadas haciendo uso de las medidas clásicas de soporte y confianza, descritas a continuación:

- **Soporte(Sop):** es la frecuencia con la que una regla se cumple en el conjunto de datos.

$$Sop(A \rightarrow C) = \frac{número\ de\ ocurrencias\ de\ A\ y\ C\ juntos}{número\ total\ de\ transacciones}$$

Ejemplo: el *Sop* de una regla A → C es el nº de transacciones en los que aparecen A y C juntos entre N, donde N es el número de transacciones existentes en BD. Si tu tienes la siguiente BD con 5 transacciones (5 listas de la compra para que lo entiendas mejor) y 5 productos distintos (A, B, C,D, E) (Tabla 2):

Tabla 2: Ejemplo de BD

Lista compra	A, B	A, B	A, C	D, E	E, C

El *Sop* de la regla A → C es 1/5 ya que A y C solo aparecen juntos en la transacción 3 y nuestra BD tiene 5 transacciones.

- **Confianza(Conf):** es el número de transacciones en las que aparecen tanto el antecedente como el consecuente[33].

$$Conf\ (A \rightarrow C) = \frac{número\ de\ ocurrencias\ de\ A\ y\ C\ juntos}{número\ de\ ocurrencias\ de\ A}$$

A pesar de su utilidad, las medidas clásicas presentan ciertos problemas, pudiendo seleccionar reglas engañosas a la hora de hacer el análisis. Por una parte, un *Sop* muy elevado para un ítem puede dar lugar a muchos itemsets frecuentes ya que puede ser añadido erróneamente a cualquier itemset sin que el soporte de este se vea afectado, acrecentando el tiempo y poder de procesamiento requerido para tratar tal cantidad de datos. Por otra parte, al no tener en cuenta el *Sop* del consecuente, *Conf* tendrá un valor elevado si una regla tiene un itemset muy frecuente en el mismo y cualquier antecedente que tenga la regla parecerá un buen predictor.

Para evitar los problemas derivados de las medidas clásicas, un gran número de nuevas medidas han sido propuestas en la literatura para clasificar y seleccionar las reglas en función de su interés para el experto. Aquellas que se han tratado con mayor atención en este TF han sido:

- **Lift:** representa la relación entre confianza y confianza esperada de una regla y tiene valores comprendidos entre 0 e infinito. Los valores superiores a 1 indican una dependencia positiva y los valores inferiores a 1 una dependencia negativa[33].

$$Lift(A \rightarrow C) = \frac{Conf(A -> C)}{Sop(C)} = \frac{Sop(AC)}{Sop(A) \cdot Sop(C)}$$

- **Leverage(Lvg):** es la diferencia entre la frecuencia observada de que A y C aparezcan juntos y la frecuencia que cabría esperar si A y C fueran independientes. Toma valores entre -1 y 1, donde aquellos inferiores a 0 representan dependencia negativa y aquellos superiores representan dependencia positiva y 0 representa independencia. Un valor de de 0 indica independencia [33].

$$Lvg(A \rightarrow C) = Sop(AC) - Sop(A) \cdot Sop(C)$$

3.3.2 Algoritmo FP Growth:

Para generar las RAs se utiliza un algoritmo que genera todos los itemsets que tengan un *Sop* igual o superior a un umbral definido por el usuario, denominados itemsets frecuentes, y después genera a partir de ellos todas las reglas que tengan una confianza igual o superior a un umbral definido por el usuario.

El algoritmo que se ha utilizado en este proyecto es FP-Growth, debido a su eficiencia y sus requerimientos más bajos de memoria y menor tiempo de ejecución. Este algoritmo genera una estructura en forma de árbol denominada FP-Tree[11].

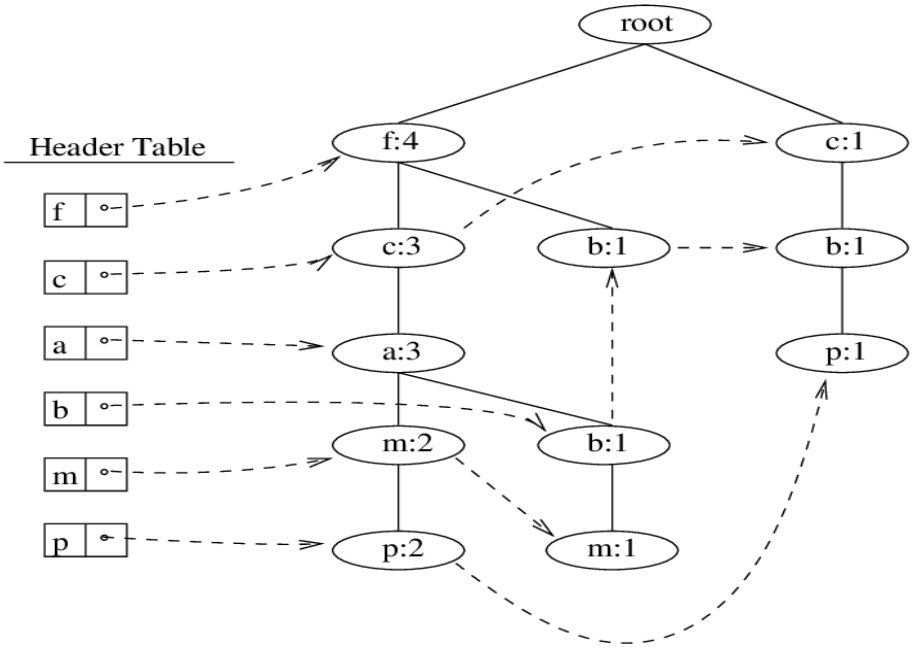

Fig. 7: Estructura FP tree [11]

Como podemos observar en la figura 7, el programa FP-growth genera la estructura FP-tree que permite conocer fácilmente cuantas veces aparece cada itemset en el conjunto de datos y extraer un conjunto de RAs para estas relaciones[1].

4. ANÁLISIS DE LOS DATOS:

Tras haber explorado las herramientas y recursos principales de este TF, se procedió al análisis principal de datos. Estos fueron extraídos con la ayuda de *TCGAbiolinks*[21] y leídos posteriormente a través de una URL mediante el paquete *pandas*[4] dentro el notebook del proyecto en *Google Colab*[32].

4.1 Exploración y formato:

Tras su lectura, los datos se sometieron a una exploración y limpieza de formato, para comprobar su correcta lectura y prepararlos para ser utilizados por FP-growth[1]. Primero se procedió a visualizar las frecuencias de los itemsets en las

distintas transacciones utilizando un diagrama de barras generado con la librería *matplotlib*[8](ver figura 8).

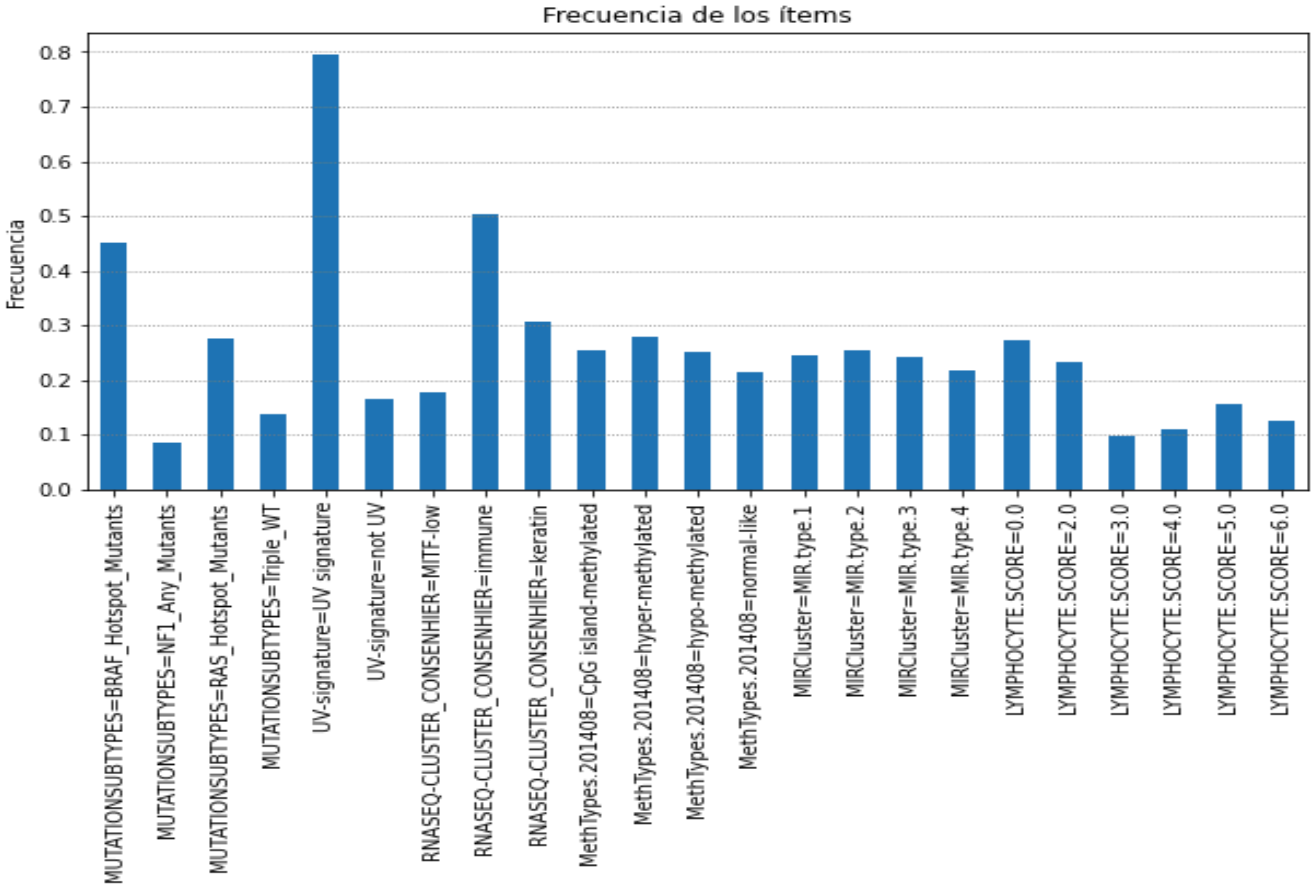

Figura 8: Diagrama de barras con las frecuencias de cada uno de los itemsets(notebook del TF, Google Colab).

Este gráfico permitió observar de manera global las distintas frecuencias, facilitando la posterior elección del *Sop* mínimo dentro de [1]. Dentro del algoritmo, este parámetro representa la mínima frecuencia con la que un itemset debe aparecer dentro de los datos para considerarse frecuente. Se observó un considerable número de frecuencias por debajo de 0,2, seleccionando en consecuencia un Sop mínimo de 0,015. Esta elección permitió que los itemsets básicos pudieran ser incluidos, evitando incluir aquellos que solo se repitieran una vez.

Habiendo obtenido este parámetro para FP-growth, se ejecutó el algoritmo. Como resultado se obtuvieron 965 itemsets frecuentes. Con el fin de obtener más

información sobre los itemsets creados se generó un diagrama de barras con la longitud de los itemsets y el número de ellos con cierta longitud como ejes, observando con una longitud predominante de 3 items por itemset(ver figura 9).

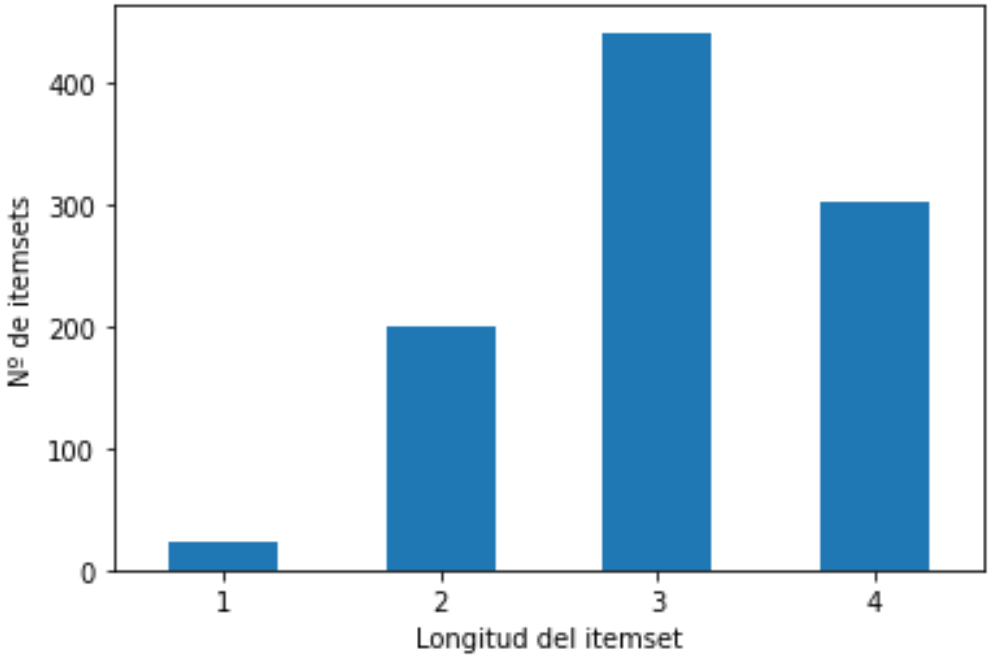

Fig. 9: Diagrama de barras representando la longitud de los itemsets (notebook del TF, Google Colab).

Una vez extraídos los itemsets frecuentes, se procedió a la generación de reglas de asociación a partir de los mismos utilizando la función *association_rules()*[33]. Para acrecentar la fiabilidad de predicción de las RAs resultantes, se seleccionó un umbral de *Conf* más elevado del normalmente utilizado por esta función, teniendo cada una de ellas no menos de un 0,85 de *Conf*. Este umbral proporcionó un mayor potencial predictivo y fidedigno de las RAs con un menor número de ellas como coste, obteniendo como resultado 317 RAs.

A continuación, se sometió a las RAs resultantes a un cribado con sus medidas de calidad, explicadas anteriormente, como filtro. Este cribado tenía como objetivo conservar las RAs más interesantes, es decir aquellas que presentaran una dependencia positiva entre el antecedente y el consecuente. Para ello se seleccionaron solo las RAs con sus valores de *Lift* > 1 y *Lvg* > 0.

Como ayuda visual se optó por un gráfico de categorías paralelas (ver figura 10), en el cual se reflejan a la derecha los consecuentes, a la izquierda los antecedentes y en el centro las dependencias existentes entre los distintos ítems, representadas por líneas. El grosor de estas representa el número de veces que se da la relación.

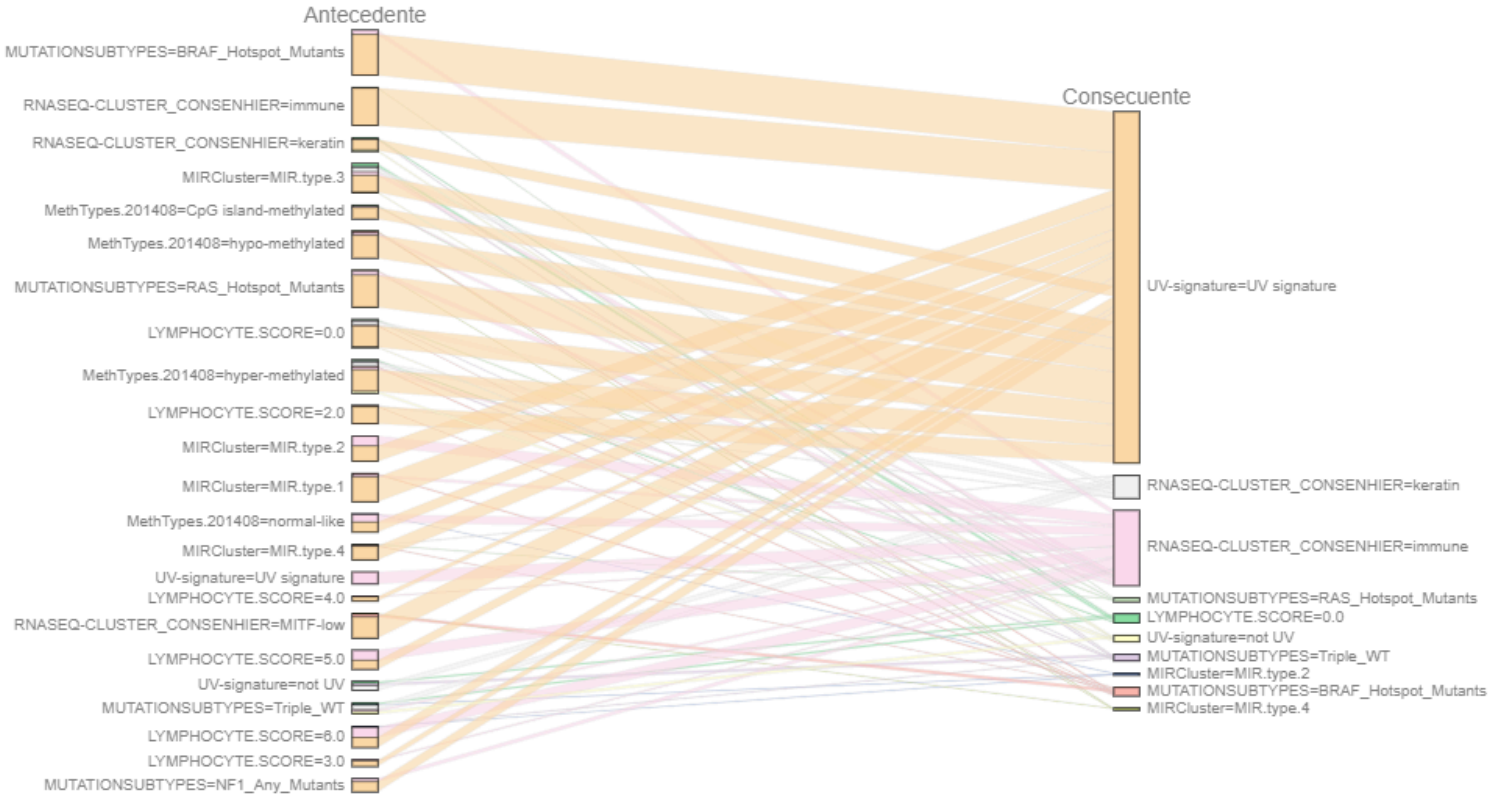

Fig 10: gráfico de categorías paralelas creado utilizando el paquete *plotly*.[15]

Se observó una gran presencia del ítem referente a la presencia de daño por radiación UV, "*UV_signature = UV signature*", el cual tiene una elevada frecuencia. Como se explicó anteriormente, si un ítem como este puede alterar el análisis ya que la medida de calidad *Conf* no tiene en cuenta su *Sop*, y no son filtradas al ejecutar la selección.

Por último se seleccionaron solo las RAs que contuviesen en el consecuente la variable *MUTATIONSUBTYPES*, ya que es la variable de interés para este TF. De este modo se podrían detectar dependencias entre las demás variables analizadas que caracterizaban a los pacientes de cada subgrupo, permitiendo establecer posibles marcadores para determinar a qué "perfil" pertenecería un paciente nuevo.

4.2 Análisis de RAs extraídas:

Como resultado de la selección anterior se obtuvieron un total de 11 RAs, listadas en la siguiente tabla (ver Tabla 3) y analizadas más adelante. En las columnas se representan de izquierda a derecha : antecedentes, consecuentes, *Conf, Sop, Lift, Lvg.*

Tabla 3: Conjunto de reglas obtenido a partir de FP-growth para la variable MUTATIONSUBTYPES

ID	Antecedente	Consecuente	Conf	Sop	Lift	Lvg
1	LYMPHOCYTE.SCORE = 0.0, MethTypes201408 = hypo-methylated, RNASEQ-CLUSTER_CONSENHIER = MITF-low	BRAF	1,00	0,02	2,22	0,01
2	MIRCluster = MIR.type.1, RNASEQ-CLUSTER_CONSENHIER = MITF-low	BRAF	0,86	0,04	1,90	0,02
3	MIRCluster = MIR.type.1, MethTypes201408 = hypo-methylated, RNASEQ-CLUSTER_CONSENHIER = MITF-low	BRAF	1,00	0,02	2,22	0,01
4	MIRCluster = MIR.type.4, MethTypes201408 = hyper-methylated, RNASEQ-CLUSTER_CONSENHIER = MITF-low	BRAF	1,00	0,03	2,22	0,02
5	LYMPHOCYTE.SCORE = 2.0, MethTypes201408 = hyper-methylated, RNASEQ-CLUSTER_CONSENHIER = MITF-low	BRAF	0,86	0,02	1,94	0,01
6	LYMPHOCYTE.SCORE = 0.0, MethTypes201408 = CpG island-methylated, RNASEQ-CLUSTER_CONSENHIER = immune	RAF	1,00	0,02	3,62	0,02
7	LYMPHOCYTE.SCORE = 0.0, MIR.type.4, MethTypes201408 = CpG island-methylated	RAF	0,86	0,02	3,10	0,01
8	LYMPHOCYTE.SCORE = 0.0, MethTypes201408 = hyper-methylated, UV_signature = not UV	Triple WT	0,86	0,02	6,20	0,02
9	MIRCluster = MIR.type.3, RNASEQ-CLUSTER_CONSENHIER = keratin, UV_signature = not UV	Triple WT	0,86	0,02	6,33	0,02
10	MIRCluster = MIR.type.3, MethTypes201408 = hyper-methylated, UV_signature = not UV	Triple WT	1,00	0,02	7,24	0,01
11	LYMPHOCYTE.SCORE = 6.0, UV_signature = not UV	Triple WT	0,86	0,02	6,33	0,02

Empezando con las mutaciones de subtipo *BRAF*, se observó generalmente la sobreexpresión de genes asociados con la pigmentación y la expresión epitelial(cluster MITF-low) y un LScore bajo. Este subtipo de mutaciones parecían relacionarse también

con la hiper e hipometilación de los locus CpG (reflejado en las reglas 1, 3 y 4) con valores de *Conf* elevados asegurando la fiabilidad de esta afirmación.

Cabe destacar que los tipos 1 y 4 del análisis de mRNA parecen tener también una dependencia para con estas mutaciones lo que sugiere que el clustering de microRNA facilita identificar con mayor certidumbre a un subgrupo concreto de sujetos que presentan el subtipo *BRAF*.

Adicionalmente, dentro de las RAs pertenecientes a *BRAF* se observaron dependencias entre el grado de metilación y los clusters de microRNA. Las RAs con hipermetilación se agruparon con el cluster de tipo 4 mientras que aquellas que presentaban hipometilación se agruparon con el cluster de tipo 1. Estos resultados indicaron que los clusters resultantes del análisis de microRNA previo, incluidos en el estudio base, contribuyeron de forma positiva a la separación de distintos perfiles de paciente (perfilado de pacientes).

Seguidamente, en las RAs con mutaciones del subtipo *RAS* se compartían dos características principales: una media de linfocitos baja (*LScore = 0*) y el locus de las islas CpG metiladas. La sobreexpresión de genes asociados con el sistema inmune pudo ser un factor influyente en este subtipo de mutación, puesto que la regla 6 presenta mayor *Conf, Lift* y *Lvg*, aun teniendo el mismo antecedente..

Es preciso denotar la importancia de la presencia de la variable LScore dentro de las RAs, debido a su relación directa con el cáncer. Un score alto en el sistema TCGA/Park utilizado tiene significancia en la prognosis de varios tipos de cáncer relacionados con los linfocitos infiltradores de tumores (TILs por sus siglas en inglés)[13] , ya que en otros estudios se ha observado pronósticos positivos en pacientes con dicho LScore[34].

Finalizando por las mutaciones de subtipo *Triple WT*, apareció en ellos una ausencia de mutaciones características de la exposición a radiación UV, ya que en todas sus RAs asociadas presenta el valor "*not UV"*. Se pudo observar también una relación de este subtipo de mutación con la hipermetilación de los locus CpG y la sobreexpresión de genes asociados a la queratina, el epitelio y la pigmentación del mismo. De igual manera los pacientes que fueron agrupados en el cluster de tipo 3 parecían tener relación con *Triple WT*.

La RA asociada a este subtipo de mutación a destacar fue la regla 10 puesto que, pese a su relativamente pequeño tamaño muestral del 1,5% del total de muestras , su fiabilidad fue la mejor ya que tiene un valor de *Conf* = 1. Siguiendo esta RA se pudo asumir con seguridad que si un paciente no presenta signos de exposición a radiación UV, presenta sus locus Cpg hipermetilados y tras un estudio de microRNA pertenece al cluster de tipo 3, expresarán siempre el subtipo *Triple WT*.

Las dependencias entre ítems de las RAs de interés se han expresado dentro de un diagrama de cuerdas utilizando el paquete *chorddiag* para una mejor visualización de los datos(ver figura 11), en el cual se pueden observar los consecuentes anteriormente comentados *BRAF, RAS* y *Triple WT* representados por secciones circulares de mayor tamaño y sus antecedentes simbolizados a su vez por líneas más pequeñas. Cada dependencia se ha representado como un trazo de color.

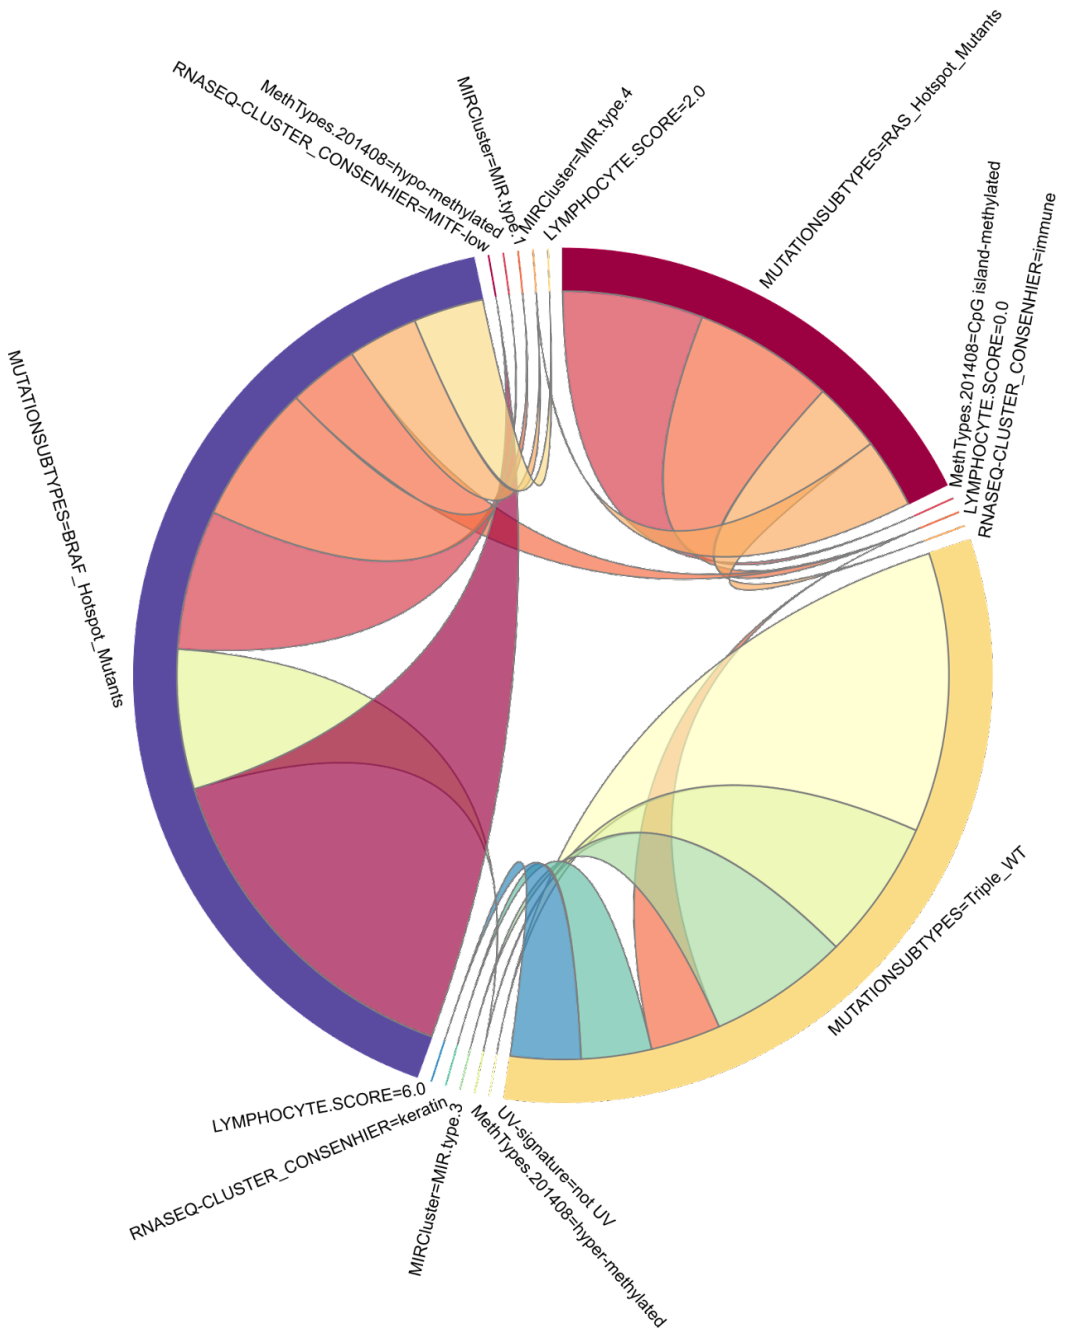

Fig 11: plot generado con el paquete chorddiag[14] con las RAs de interés

La visualización de los datos en este formato facilitó la extracción de información útil y debido a su diseño interactivo, sencillo y atractivo fue elegida para ser utilizada en la app.

De esta manera se pudo corroborar la concordancia de las observaciones dentro del diagrama de la figura 11 con lo anteriormente analizado en las RAs

expuestas en la Tabla 3. A su vez, también concuerdan con dependencias comprobadas en el estudio original, como la anteriormente mencionada entre el subtipo *Triple WT* y la poca prevalencia de estas en los datos que presentan el indicador de daños por radiación UV[6].

Las RAs extraídas en conjunto con otras observaciones referentes a la edad de los sujetos con cierto tipo de mutaciones podría dar un buen "perfil" para identificar qué tipo de mutación posee cada paciente, y como consecuencia refinar su tratamiento.

5. DESARROLLO DE LA APP SHINY:

Como ya se comentó anteriormente, a la hora de desarrollar la app se ha tenido en cuenta la limpieza y la simple utilización ante todo, puesto que su propósito es facilitar la accesibilidad de los datos anteriormente analizados a un público potencialmente no versado en informática, análisis de datos o genómica.

Al estar basado en la accesibilidad, este TF tomó Shiny como base para desarrollar la app, puesto que es una potente herramienta de R para la creación de apps de manera sencilla y es accesible a todo el mundo. También se tomó en cuenta su diseño gráfico, ya que al ser más austero de base que otras opciones mantendría el foco de atención sobre los datos expuestos en la app resultante.

5.1 Diseño de la UI:

En consecuencia con lo anteriormente dicho, la interfaz de usuario (UI por si siglas en inglés) debía ser sencilla pero llamativa. Por ese motivo, se tenían que eliminar del diseño todos aquellos elementos e información que fuese una distracción,

necesitasen de conocimientos avanzados de informática o estadística o simplemente no fuesen relevantes.

Se optó por un diseño tipo “dashboard” debido a que ofrece un diseño más dinámico que la página web básica, cambiando el desplazamiento vertical (scrolling) por una serie de pestañas(tabs). Cada una de estas tabs permite encapsular dentro de cajas todo tipo de contenido, lo que aportaba beneficios como la legibilidad, manteniendo a la vez el contenido en un lugar concreto.

Tras elegir el tipo de diseño global dentro de Shiny, se elaboró un listado lo más sencillo posible que contenía los elementos necesarios para que la app pudiese transferir de manera exitosa el conocimiento anteriormente analizado y seleccionado. Este debía contener los siguientes elementos:

- Título de la app
- Menú
- Breve explicación de la app
- Elementos informativos sobre los datos analizados
- Diagrama de cuerdas
- Explicación sobre los datos visualizados
- RAs desglosadas

Otro punto importante fue el uso de colores e iconos explicativos para dar una capa de funcionamiento intuitivo a la base de la app.

Más tarde se comenzó a decidir la forma y la colocación de los diferentes elementos de la UI. Para tener una idea inicial se elaboraron diversas maquetas(mockups) para cada sección que contendría la app que han sido discutidas a continuación(ver figuras 14 a 17).

Fig 14: Mockup de la sección “Diagramas” de la app (elaboración propia)

En la figura anterior se puede observar como del esquema circular, visto también en la figura 11, saldrían varios tabs que tendrían información sobre las variables representadas. También podemos observar un icono de engranaje donde estaría el botón de menú y el subsecuente menú desplegable justo debajo.

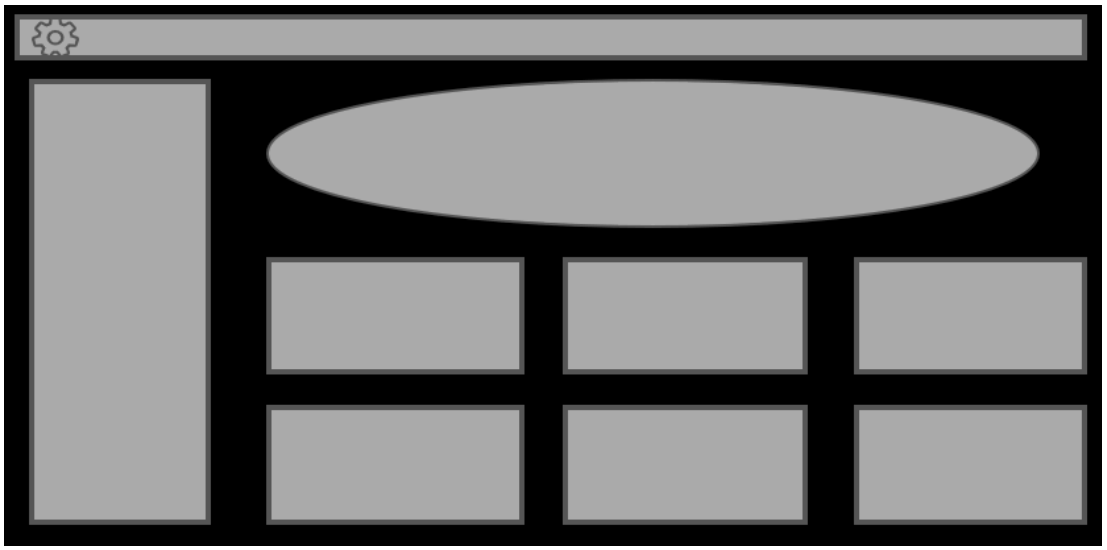

Fig 15: Mockup de la sección “Variables” de la app (elaboración propia)

En la figura 15 se observa como una parte de la página estaría ocupada por un óvalo, representando el título explicativo de toda la sección, seguido de varios tabs que contendrán una descripción de las variables y las medidas de calidad utilizadas en las RAs, representados por los rectángulos más pequeños.

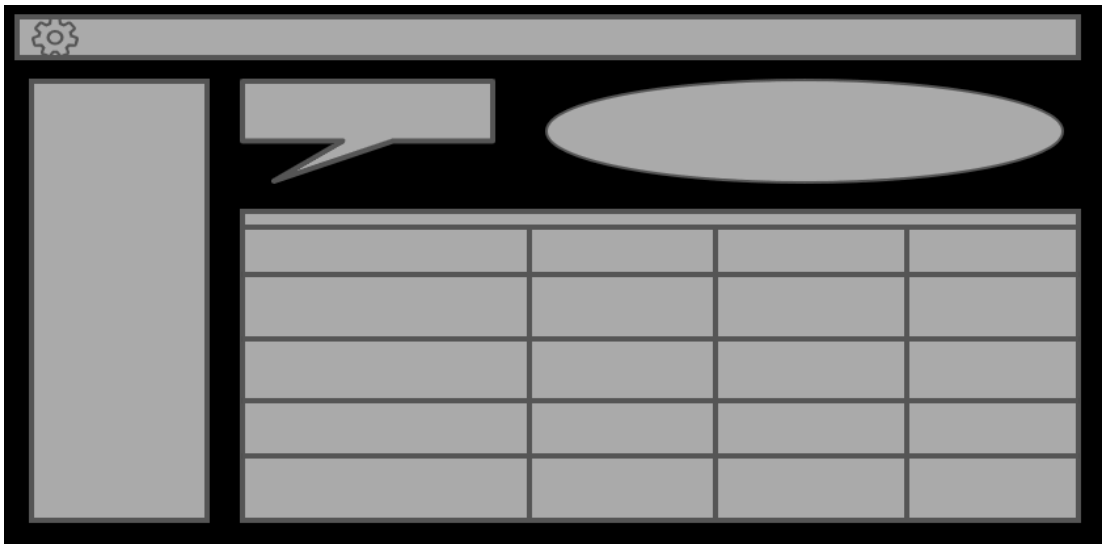

Fig 16: Mockup de la sección “RAs desglosadas” de la app (elaboración propia)

Como se puede observar en la figura 16, la sección RAs desglosadas tendría un input interactivo, representado por el bocadillo rectangular de la parte superior izquierda, que permitiría seleccionar el consecuente del cual se expondrían las RAs en su totalidad en la tabla, representada por el rectángulo tabulado del centro. Esta tabla ocuparía la gran mayoría del espacio de la sección, puesto que contiene todos los antecedentes de cada regla, sus medidas de calidad y el consecuente seleccionado.

Este último sería recalcado visualmente dentro de un aviso interactivo, representado por el óvalo, que cambiaría junto con el consecuente seleccionado. Este detalle se eligió como medida para aumentar la legibilidad de la página, puesto que no deja lugar a duda sobre qué consecuente está activo y qué set de RAs se está enseñando por pantalla.

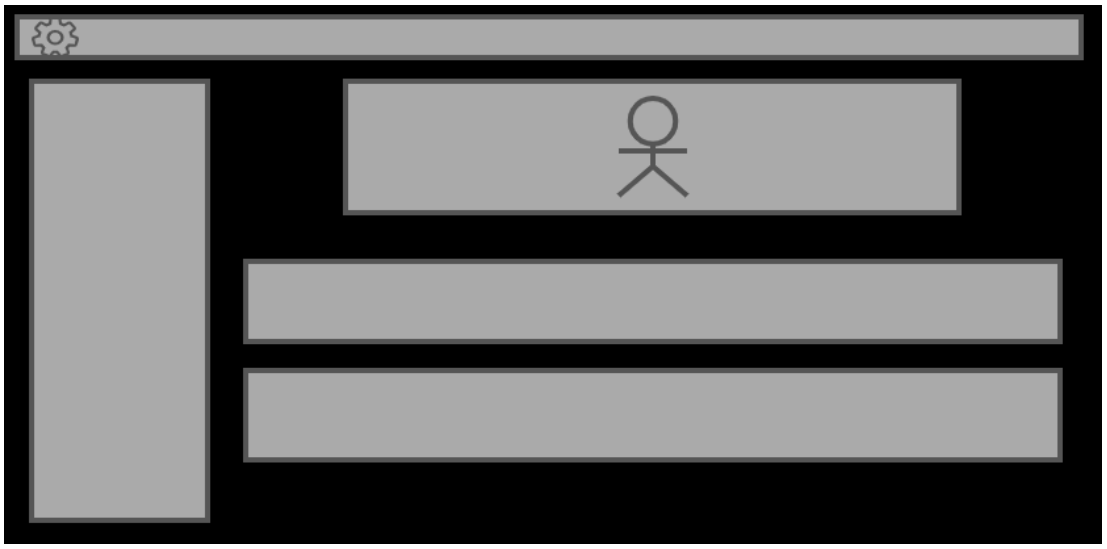

Fig 17: Mockup de la sección “Inicio” de la app (elaboración propia)

Finalmente se propuso la disposición representada en la figura 17 para la sección inicial de la app. Tendría una breve descripción de este TF en el tab representado con el rectángulo con la persona, acompañado de otros tabs con información resumida necesaria, que no estuviera necesariamente recogida dentro de la sección variables.

5.2 Escritura del código fuente y despliegue de la app:

La realización del código empezó con la creación de un fichero que contuviera tanto el archivo de R con el código de la app, como los datos guardados desde el notebook, en formato “.csv”.

Una vez instaladas las dependencias principales de Shiny, se procedió a escribir las bases para la ui y el server de la app y se utilizó el paquete *semantic.dashboard* para facilitar la personalización de toda la UI para este TF.

Dentro de la sección de código correspondiente a la UI se leyeron los datos guardados anteriormente en la carpeta “*data”*:

- ***reglas_asoc.csv:*** contiene las RAs extraídas con todos los datos.

- ***lista_items.csv:*** contiene una lista de items con los nombre de los antecedentes y consecuentes
- ***matriz_adyacencia_porgrupos.csv:*** contiene la matriz de adyacencia creada en el notebook preparada para ser introducida en la función *chorddiag()*

Posteriormente se completó el código de la UI, asignando un título al banner del menú y nombrando todas las secciones.

Cada una de ellas fue poblada con "cajas" de código que contienen los elementos informativos principales de la app. Esta estructura de código permitió la personalización de los elementos, añadiendo colores personalizados y un título identificativo en forma de cinta o lazo.

El texto de cada sección se editó con ayuda de código html que facilitó cambios como el tamaño o el peso de letra o la posición de iconos. En cuanto a estos últimos, fueron seleccionados para cada una de las secciones desde el repositorio de iconos de Font Awesome[36], para añadirles distinción. También se utilizaron iconos especiales dentro de las secciones, en concreto en las cabeceras descriptivas de cada uno.

Dentro de una de las cajas, se añadió el código necesario para reproducir el diagrama de cuerdas, visto en la figura 11, mediante la función *chorddiagOutput()*, especializada para su uso en una app Shiny.

Por otro lado, en la sección de código correspondiente al server se configuraron los inputs reactivos, la tabla de desglose de RAs y el código para generar el diagrama de cuerdas utilizando los archivos *lista_items.csv* y *matriz_adyacencia_porgrupos.csv* en conjunto con la función *chorddiag()* cuyo output está conectado a la función *chorddiagOutput()*.

Finalmente se compiló todo el proyecto dentro de la carpeta "*TFM_ShinyApp*" y se desplegó la aplicación a la web mediante ShinyApps.io[37]

5.3 Vista general de la app:

5.3.1 Título de la app y menú desplegable:

Para que fuera visible el propósito de la app, se posicionó en un cartel (banner en inglés) en la parte superior izquierda de la app así como un botón con el menú (ver figuras 14 y 15).

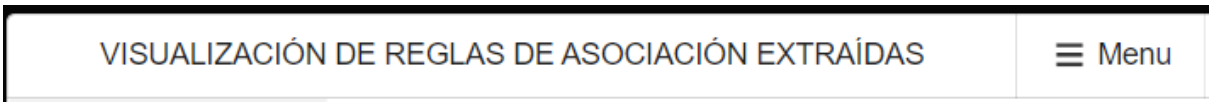

Fig 18: captura de pantalla del banner principal de la app[35]

Se optó por un banner simple y sin logo, con el botón de menú interactivo, que al activarse controla la visibilidad del mismo, pudiendo ocultarlo para una visibilidad más centrada de los elementos informativos.

Fig 19: captura de pantalla del menú desplegable de la app[35]

Los iconos elegidos para las secciones tenían el objetivo de diferenciar a cada una de ellas de las demás a la par que no parecer básicas, para captar la atención del usuario.

5.3.2 Secciones de la app:

Cada una de las secciones tiene una distribución diferente, que ha tomado como referencia los mockups anteriormente comentados.

- **Inicio - TFM**

En primer lugar, la sección “Inicio - TFM” cuenta con un total de 5 elementos informativos. Está pensada como una vía de entrada a la app y al propósito por el cuál se ha creado, explicando a su vez los aspectos cruciales y las bases de este TF de manera sencilla.

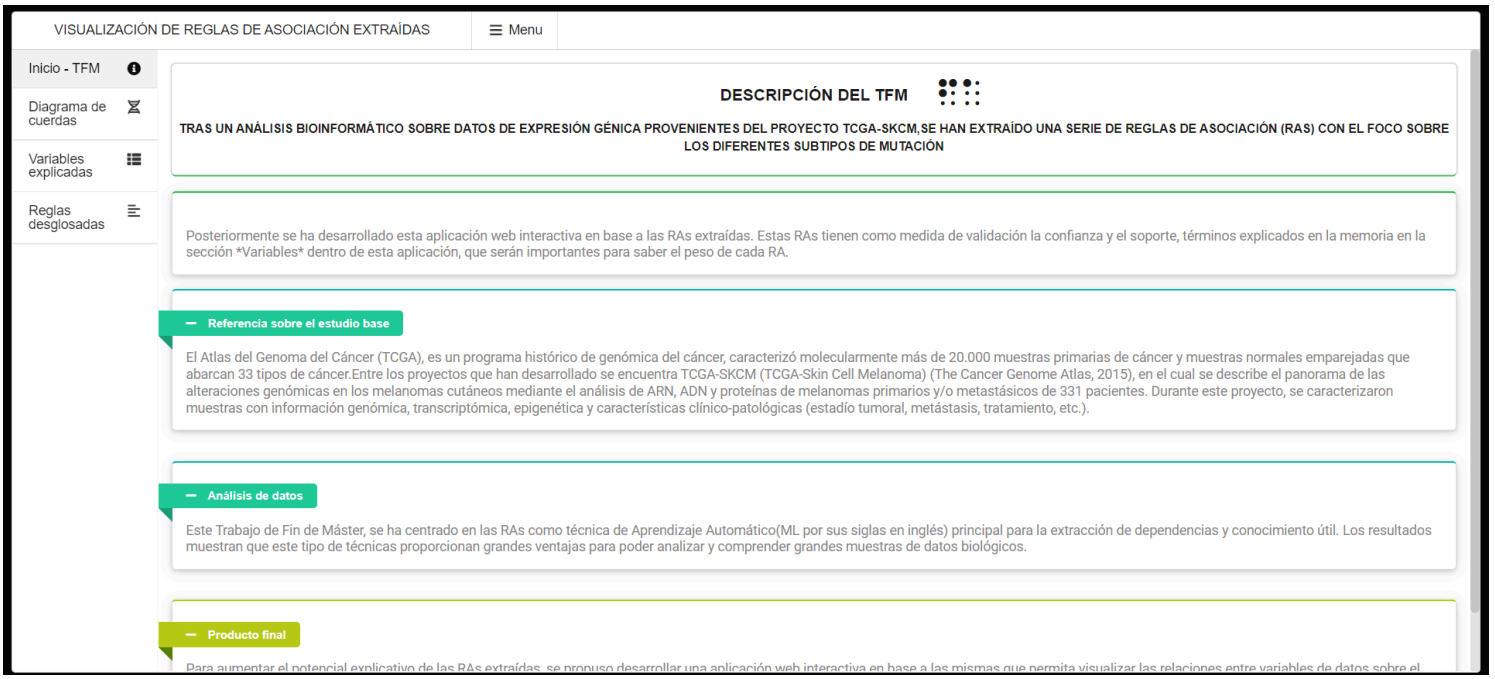

Fig 20: captura de pantalla de la sección “Inicio - TFM” de la app[35]

La parte superior está ocupada por una pequeña descripción de TF, seguida de un segundo elemento sin título que sirve como su continuación. Justo debajo se encuentran una pequeña referencia sobre el estudio base[6] y unas frases sobre el potencial del ML. En la parte inferior, una explicación del por qué se creó esta app.

Se ha conseguido replicar la disposición planteada en el diseño de esta sección, con la adición de varios elementos informativos que han aprovechado el espacio restante, reduciendo la sensación de página vacía.

- **Diagrama de cuerdas**

Siguiendo con esta sección, se ha poblado la página con 5 elementos que, si bien cumplen una función parecida a los de la sección anterior, tienen un contenido totalmente diferente.

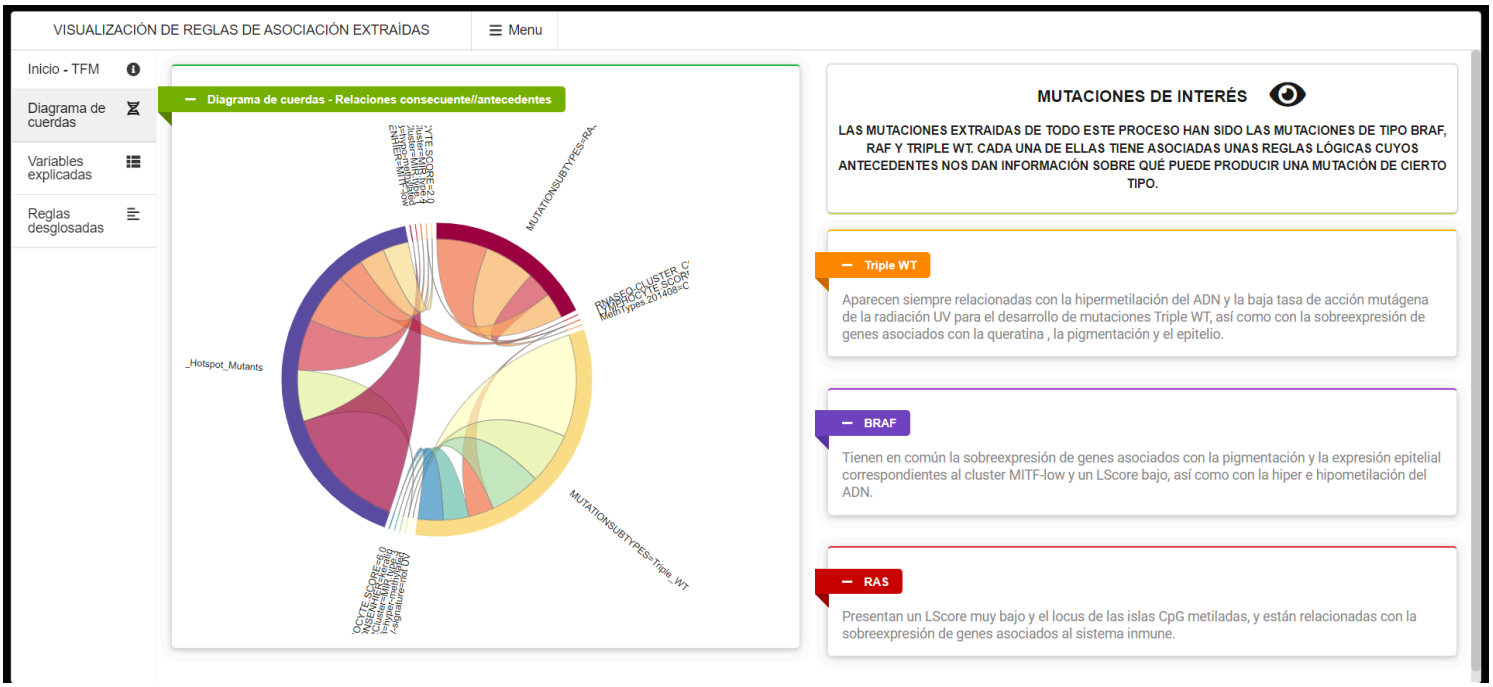

Fig 21: captura de pantalla de la sección “Diagrama de Cuerdas” de la app[35]

La sección se ha diseñado de manera que el diagrama de cuerdas sea el centro de atención, puesto que es la fuente principal de información de esta sección. También es necesario destacar la interactividad del gráfico, ya que cuando se pasa el cursor por encima de una de las conexiones, se devuelve por pantalla la RA asociada en su totalidad.

La parte derecha de la página está dedicada a elementos de información que apoyan al diagrama de cuerdas, ofreciendo una descripción de los subtipos de

mutación que se obtuvieron como consecuentes en el análisis. Se encuentran supeditadas a un tab descriptivo con un icono en forma de ojo para llamar la atención del usuario, aporte cuya adicción fue una mejora de diseño sobre el esquema inicial de esta sección.

- **Variables explicadas**

La tercera sección es de carácter explicativo en su totalidad, habiendo sido concebida como una página de apoyo para informar al usuario sobre las variables encontradas en los antecedentes y las medidas de calidad utilizadas por las RAs.

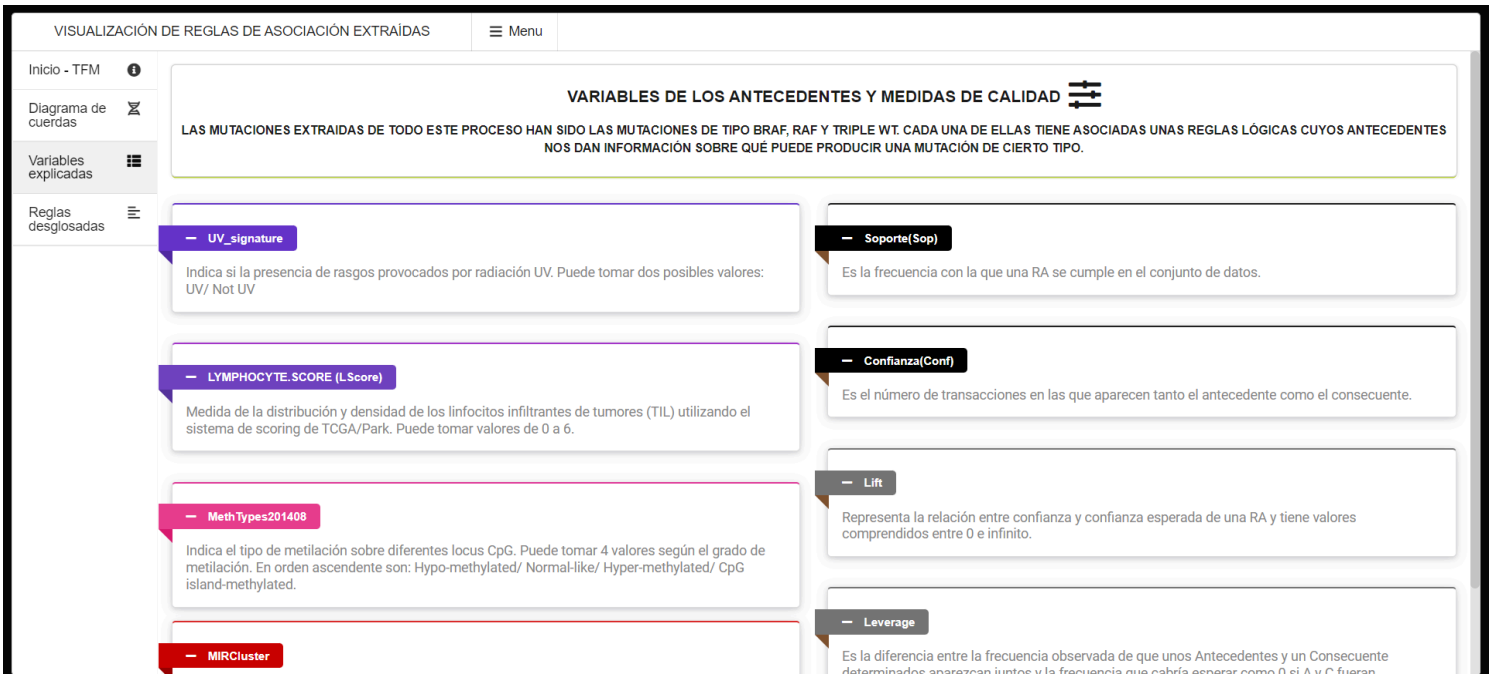

Fig 22: captura de pantalla de la sección “Variables explicadas” de la app[35]

Alojada en la parte superior, se encuentra el título explicativo de la página junto con un icono, una vez más, para atraer la atención del usuario intentando propiciar que la lectura de la página se empiece por aquí.

El resto de los elementos informativos se dividen en dos grupos, diferenciados por su esquema de colores. Aquellos elementos que tiene información sobre las variables interés se encuentran a la izquierda, portando una paleta de colores violetas y rojizos, mientras que los elementos relacionados con las medidas de calidad se

posicionan a la derecha con una paleta de colores negro-gris. Esta última diferenciación de colores separa a su vez las medidas clásicas de las medidas más actuales que soportan a las anteriores.

- **Reglas desglosadas**

Por último, la cuarta sección de la app es junto con la segunda, la más dinámica de la app y su diseño da protagonismo a las RAs, como su nombre indica.

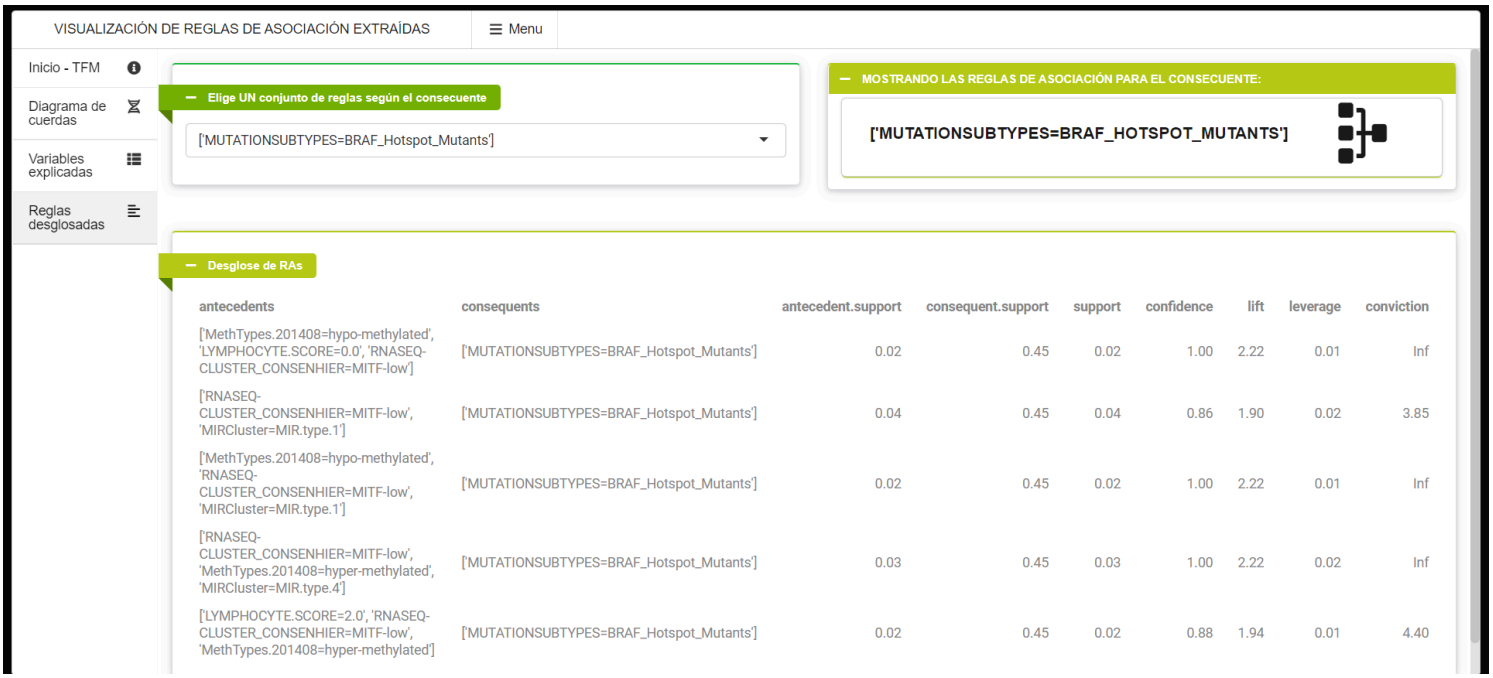

Fig 23: captura de pantalla de la sección “Reglas desglosadas” de la app[35]

Su disposición es la más parecida al diseño comentado anteriormente, con gran parte de la página ocupada por una tabla de desglose, que contiene todas las RAs asociadas a un consecuente.

La parte superior está ocupada por un elemento de selección reactivo y otro elemento de apoyo visual, supeditado al anterior (ver figura 24). Se creyó conveniente utilizar un selector, en lugar de mostrar por pantalla todas las RAs al mismo tiempo. De esta manera el usuario decide qué ver.

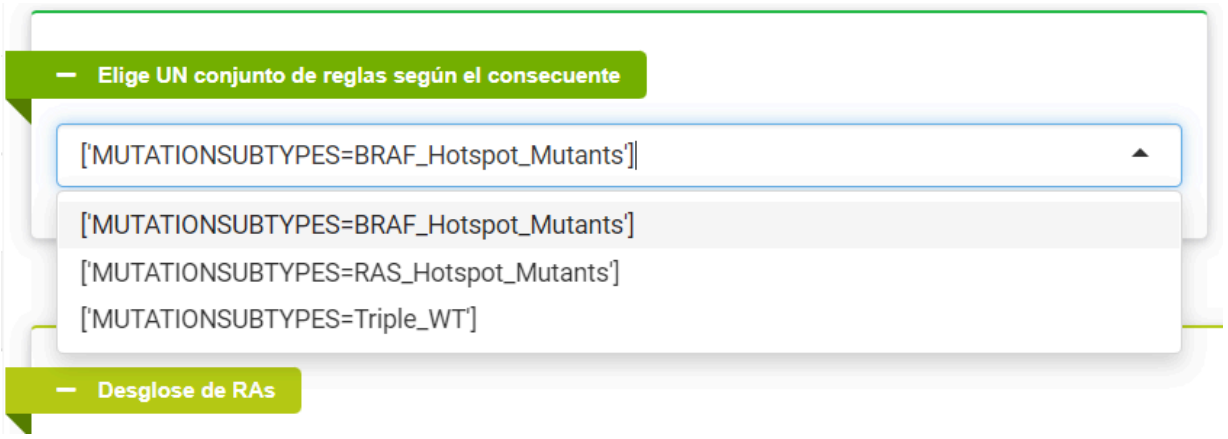

Fig 24: captura de pantalla del menú selector dentro de la sección “Reglas desglosadas” [35]

El elemento de apoyo ha sido mejorado con la adición de un icono con el suficiente tamaño para llamar la atención del usuario, con el fin de facilitar la visualización del consecuente seleccionado(ver figura 25). Al ser reactivo, el consecuente que muestra corresponderá siempre al elegido en el menú selector anteriormente comentado.

Fig 25: captura de pantalla del menú selector dentro de la sección “Reglas desglosadas” [35]

6. IMPLEMENTACIÓN Y USO:

Para utilizar la app, los potenciales usuarios no necesitan instalar ningún paquete ni utilizar ninguno de los materiales tratados anteriormente. Basta con que accedan a ella a través de la dirección de ShinyApps.io en la cual está alojada, citada en la bibliografía [33]. La dirección en cuestión es la siguiente: http://0dt2j0-manuel-mar0n0fern0ndez.shinyapps.io/TFMVisualizing_ShinyApp?_ga=2.21461692.625687368.1673367320-911810903.1673367320

7. CONCLUSIONES Y TRABAJOS FUTUROS:

Tras el análisis de datos de TCGAbiolinks[21], que habían sido preprocesados en el estudio base[6], se ha procedido a la extracción de las RAs. Una vez analizadas, se han diferenciado por sus consecuentes en 3 subtipos de mutaciones de interés. Cada uno de ellos parece exhibir una serie de características, que se suelen repetir dentro de cada subtipo de mutación. Por un lado, el subtipo BRAF se ha caracterizado por la sobreexpresión de genes relacionados con la pigmentación y la expresión epitelial junto con una distribución y densidad de linfocitos baja y un alto grado de metilación de los locus CpG. Con respecto al subtipo RAS, los rasgos destacados son la sobreexpresión de genes asociados al sistema inmune, una distribución y densidad de linfocitos baja y una metilación de los locus CpG de tipo isla. Por otro lado, el subtipo Triple WT ha aparecido siempre con sobreexpresión de los genes asociados a la queratina.

La información extraída de estas mutaciones se utilizaron como estaba previsto, para la creación de una app. Esta se ha diseñado de manera que los datos pudiesen ser accesibles a todo el mundo, pero que fuesen de utilidad al personal especializado en salud, en concreto en campos relacionados con el cáncer de melanoma como la oncología. Por eso las variables que se han representado en la aplicación son un poco específicas aun pudiendo explicarse de manera simplificada. La app resultante ha cumplido con las expectativas que este TF tenía, aunque siempre con un márgen de mejora.

Los objetivos planteados inicialmente se han ido cumpliendo conforme a la planificación comentada al principio de esta memoria, aunque existen algunas excepciones. Debido a la descontinuación de las librerías de *chorddiag*, este paquete ha provocado un problema de incompatibilidad imprevisto que se solventó tras migrar de entorno, retrasando el cumplimiento de los objetivos finales.

Los impactos previstos en el aspecto de sostenibilidad se han logrado dentro del marco del TF, aunque quedaría por saber su verdadera utilidad mediante la utilización de apps parecidas con datos de pacientes reales. Por otra parte, se ha seguido la solución propuesta dentro del apartado de impacto ético social respecto a la problemática de la privacidad de datos, solventando dicho problema dentro de este TF puesto que los datos son de libre acceso. Si en un futuro se aplicase este modelo de app a una escala mayor tendría que realizarse una nueva evaluación del impacto que podría tener la recolección de datos y una vez conocido, implantar los controles y medidas necesarios para garantizar la seguridad de los datos.

Finalmente, con respecto al apartado de diversidad y derechos humanos ha estado enfocado en la accesibilidad de información, cuestión comentada numerosas veces a lo largo de la memoria. El posible sesgo de los datos de base se podría paliar si en el futuro, a la hora de implementar este tipo de aplicaciones se utilizan datos con cohortes más amplias, tomando en cuenta los ODS [38] como criterios de selección, siempre teniendo en cuenta qué se busca con cada estudio para no abarcar demasiado y evitar obtener datos demasiado generalizados.

8. GLOSARIO:

- ML - Aprendizaje automático (Machine Learning en inglés)
- App - Aplicación
- TCGA - The Cancer Genome Atlas
- TCGASKCM - The Cancer Genome Atlas Skin Cell Melanoma (proyecto)
- Mockup - maqueta
- IA - Inteligencia artificial
- TILs - linfocitos infiltradores de tumores (tumor infiltrating lymphocytes en inglés)
- TBI -Bioinformática traslacional (Translational Bioinformatics en inglés)
- BD/BDs - base/s de datos de datos
- RA/RAs- regla/s de asociación
- LScore - medida de distribución y densidad de TILs [13]

9. BIBLIOGRAFÍA:

1. Raschka, S. *Fpgrowth Algorithm - mlxtend*. In: GitHub [Internet]. Available from: http://rasbt.github.io/mlxtend/user_guide/frequent_patterns/fpgrowth/

2. Agrawal, R., Imielinski, T., & Swami, A.(1993). *Mining association rules between sets of items in large databases*. ACM SIGMOD Record, vol. 22, Issue 2, 207–216.DOI:10.1145/170036.170072

3. Schatton T, Scolyer RA, Thompson JF, Mihm MC Jr. (2014).*Tumor-infiltrating lymphocytes and their significance in melanoma prognosis*. Methods in molecular biology, vol. 1102,287-324. DOI:10.1007/978-1-62703-727-3_16

4. Mckinney, Wes.(2011). *pandas: a Foundational Python Library for Data Analysis and Statistics*. Python High Performance Science Computer, 1-9.

5. Li, B., Dewey, C.N. (2011) *RSEM: accurate transcript quantification from RNA-Seq data with or without a reference genome*.BMC Bioinformatics, vol. 12, Art no.323. DOI:10.1186/1471-2105-12-323

6. Cancer Genome Atlas Network. *Genomic Classification of Cutaneous Melanoma*. Cell, vol. 161, Issue 7, (2015) 1681–1696. DOI:10.1016/j.cell.2015.05.044

7. Raschka, S. MLXTEND Library. (sin fecha). In: GitHub [Internet]. Available from: http://rasbt.github.io/mlxtend/

8. Barrett, Paul & Hunter, J. & Miller, J.T. & Hsu, J.-C & Greenfield, P. (2005) *matplotlib -- A Portable Python Plotting Package*. Astronomical Data Analysis Software and Systems XIV, Volume 347, 91-95

9. RPy2 3.5.0 - dev documentation. (sin fecha). In: GitHub [Internet]. Available from: https://rpy2.github.io/doc/latest/html/index.html

10. Harris, C.R., Millman, K.J., van der Walt, S.J. et al.(2020) *Array programming with NumPy*. Nature, vol. 585, 357–362. DOI:10.1038/s41586-020-2649-2

11. Ozkural, E & Aykanat, C. *A Space Optimization for FP-Growth*. Proceedings of the IEEE ICDM Workshop on Frequent Itemset Mining Implementations,(FIMI 2004), Brighton (UK), November 1, 2004.

12. Briggs FBS, Sept C. (2021) *Mining Complex Genetic Patterns Conferring Multiple Sclerosis Risk*. International Journal of Environmental Research and Public Health, vol. 18, Issue 5, 2518. DOI:10.3390/ijerph18052518

13. Park, C. K., & Kim, S. K. (2017) *Clinicopathological significance of intratumoral and peritumoral lymphocytes and lymphocyte score based on the histologic subtypes of cutaneous melanoma*. Oncotarget, vol. 8, Issue 9, 14759–14769. DOI:10.18632/oncotarget.14736

14. Flor, M - *chorddiag*. In GitHub [Internet]. Available from : https://github.com/mattflor/chorddiag

15. Plotly Express (sin fecha). In: Plotly [Internet]. Available from: https://plotly.com/python/plotly-express/

16. Lantz, B. (2015). *Machine Learning with R - Second Edition*[Libro]. Packt Publishing, Limited.

17. Deepak Painuli, Suyash Bhardwaj, Utku köse (2022) . *Recent advancement in cancer diagnosis using machine learning and deep learning techniques: A comprehensive review*, Computers in Biology and Medicine, Volume 146, 105580, ISSN 0010-4825, https://doi.org/10.1016/j.compbiomed.2022.105580

18. Chang W, Cheng J, Allaire J, Sievert C, Schloerke B, Xie Y, Allen J, McPherson J, Dipert A, Borges B (2023). *shiny: Web Application Framework for R*. R package version 1.7.4.9001, https://shiny.rstudio.com/.

19. E. Rammant, E. Deman, L. Poppe, R. Bultijnck, P. Dirix, G. De Meerleer, K. Haustermans, A. Van Hecke, D. Azria, J. Chang-Claude, A. Choudhury, D. De Ruysscher, M. Lambrecht, B.S. Rosenstein, P. Seibold, E. Sperk, R.P. Symonds, R. Valdagni, A. Vega, A. Webb, C. West, L. Veldeman, V. Fonteyne, S. Van Hoecke, *A1153 - Predicting patient-reported symptom clusters in prostate cancer patients: A machine learning approach*, European Urology, Volume 81, Supplement 1, 2022, Pages S1687-S1688 . https://doi.org/10.1016/S0302-2838(22)01229-5

20. TCGA (The Cancer Genome Atlas) (sin fecha). In: National Cancer Institute [Internet] Available from: https://www.cancer.gov/about-nci/organization/ccg/research/structural-genomics/tcga

21. Colaprico, A., Silva, T. C., Olsen, C., Garofano, L., Cava, C., Garolini, D., Sabedot, T. S., Malta, T. M., Pagnotta, S. M., Castiglioni, I., Ceccarelli, M., Bontempi, G., & Noushmehr, H. (2016). *TCGAbiolinks: an R/Bioconductor package for integrative analysis of TCGA data*. Nucleic acids research, vol. 44, Issue 8, e71. DOI:10.1093/nar/gkv1507

22. Jiawei Han, Jian Pei, and Yiwen Yin.(2000). *Mining frequent patterns without candidate generation*. ACM SIGMOD Record, vol. 29, Issue 2 , 1–12. DOI:10.1145/335191.335372

23. Matthews, N. H., Li, W.-Q., Qureshi, A. A., Weinstock, M. A., & Cho, E.. (2017). *Epidemiology of Melanoma* [Libro](pp. 3–22). https://doi.org/10.15586/codon.cutaneousmelanoma.2017.ch1

24. Sarkar, I. N., Butte, A. J., Lussier, Y. A., Tarczy-Hornoch, P., & Ohno-Machado, L. (2011). *Translational bioinformatics: linking knowledge across biological and clinical realms*. Journal of the American Medical Informatics Association : JAMIA, 18(4), 354–357. https://doi.org/10.1136/amiajnl-2011-000245

25. Regan, K., & Payne, P. R. (2015). *From Molecules to Patients: The Clinical Applications of Translational Bioinformatics*. Yearbook of medical informatics, 10(1), 164–169. https://doi.org/10.15265/IY-2015-005

26. Satagopam, V., Gu, W., Eifes, S., Gawron, P., Ostaszewski, M., Gebel, S., Barbosa-Silva, A., Balling, R., & Schneider, R. (2016). *Integration and Visualization of Translational Medicine Data for Better Understanding of Human Diseases*. Big data, 4(2), 97–108. https://doi.org/10.1089/big.2015.0057

27. Suresh K. Bhavnani, Mamta Abbas, Vickie McMicken, Numan Oezguen, and Jeffry A. Tupa. (2012). *ICircos: visual analytics for translational bioinformatics*. In Proceedings of the 2nd ACM SIGHIT International Health Informatics Symposium (IHI '12). Association for Computing Machinery, New York, NY, USA, 679–684. https://doi.org/10.1145/2110363.2110440

28. Atul J. Butte, MD, PhD,(November 2008). *Translational Bioinformatics: Coming of Age*, Journal of the American Medical Informatics Association, Volume 15, Issue 6, Pages 709–714, https://doi.org/10.1197/jamia.M2824

29. Jones, B. C., Lipson, E. J., Childers, B., Fishman, E. K., & Johnson, P. T. (2018). *State-of-the-Art Diagnosis and Treatment of Melanoma: Optimal Multidetector Computed Tomographic Practice to Identify Metastatic Disease and Review of Innovative Therapeutic Agents*. Journal of computer assisted tomography, 42(3), 331–339. https://doi.org/10.1097/RCT.0000000000000697

30. Guhan, S., Klebanov, N., & Tsao, H. (2021). *Melanoma genomics: a state-of-the-art review of practical clinical applications*. The British journal of dermatology, 185(2), 272–281. https://doi.org/10.1111/bjd.20421

31. Yeh, I., Jorgenson, E., Shen, L., Xu, M., North, J. P., Shain, A. H., Reuss, D., Wu, H., Robinson, W. A., Olshen, A., von Deimling, A., Kwok, P. Y., Bastian, B. C., & Asgari, M. M. (2019). *Targeted Genomic Profiling of Acral Melanoma.* Journal of the National Cancer Institute, 111(10), 1068–1077. https://doi.org/10.1093/jnci/djz005

32. Bisong, E. (2019). Google Colaboratory. In: Building Machine Learning and Deep Learning Models on Google Cloud Platform. Apress, Berkeley, CA. https://doi.org/10.1007/978-1-4842-4470-8_7

33. Raschka, S. (sin fecha). *Association rules - mlxtend*. In: GitHub [Internet]. Available from: http://rasbt.github.io/mlxtend/user_guide/frequent_patterns/association_rules/

34. Bogunovic, D., O'Neill, D. W., Belitskaya-Levy, I., Vacic, V., Yu, Y. L., Adams, S., Darvishian, F., Berman, R., Shapiro, R., Pavlick, A. C., Lonardi, S., Zavadil, J., Osman, I., & Bhardwaj, N.(2009).

Immune profile and mitotic index of metastatic melanoma lesions enhance clinical staging in predicting patient survival. Proceedings of the National Academy of Sciences of the United States of America, vol. 106, Issue 48, 20429–20434. DOI:10.1073/pnas.0905139106

35. Marin, M. (2022). *Visualización de Reglas de Asociación extraídas*. In ShinyApps.io [Internet] . http://0dt2j0-manuel-mar0n0fern0ndez.shinyapps.io/TFMVisualizing_ShinyApp?_ga=2.21461692.625687368.1673367320-911810903.1673367320

36. Iannone R (2022). *fontawesome: Easily Work with 'Font Awesome' Icons*. In: GitHub [Internet]. Available from: https://github.com/rstudio/fontawesome

37. ShinyApps.io (sin fecha). [página web]. Available from: https://www.shinyapps.io/

38. United Nations. (sin fecha). *Home - United Nations Sustainable Development*. United Nations. Available from https://www.un.org/sustainabledevelopment/